

# 概率论与数理统计

Karry Ren

在我看来，概率论与数理统计是最重要的一门数学课，是当下金融学、人工智能的本质基础，是刻画世界的最有力的工具。因此我的后半生一定会一直和其打交道，考虑到之前的学习过程比较分散，未形成自己的体系。从 2023 年 8 月开始整理此笔记，目的就是打造一则最完善的概率论与数理统计基础宝典，再次疏通整个概率论数理统计框架，掌握最基础最深层次的含义，并用自己的话加以描述，为日后的使用奠定坚实的基础。

本笔记参考茆诗松老师的教材整理而来，常见题目出自考研课程。

## 概率论与数理统计

### 第一章 随机事件与概率

#### 1.1 随机事件及其运算

#### 1.2 概率的定义及其确定方法

##### 1.2.1 概率的公理化定义

##### 1.2.2 概率的确定方法

###### a. 确定概率的古典方法

###### b. 确定概率的几何方法

#### 1.3 概率的性质

##### 1.3.1 概率的基本性质

##### 1.3.2 条件概率及其性质

###### a. 条件概率的定义

###### b. 全概率公式

###### c. 贝叶斯公式

##### 1.3.3 独立性

###### a. 定义

###### b. 性质

#### 1.4 考点与典例

##### 1.4.1 考点（量化笔试就曾出现过考研原题）

##### 1.4.2 典例

### 第二章 随机变量及其分布

#### 2.1 随机变量及其分布的概念

##### 2.1.1 随机变量

##### 2.1.2 分布函数

###### a. 定义

###### b. 性质（分布函数的三点性质）

##### 2.1.3 分布函数的形式

###### a. 离散变量的分布列

###### b. 连续变量的概率密度函数

#### 2.2 随机变量的数字特征

##### 2.2.1 $k$ 阶矩

##### 2.2.2 数学期望（1 阶原点矩）

###### a. 定义

###### b. 性质

##### 2.2.3 方差 & 标准差（2 阶中心矩）

###### a. 定义

###### b. 性质

c. 切比雪夫不等式

### 2.2.3 变异系数

### 2.2.4 分位数 ( $p$ 值、中位数)

### 2.2.5 偏度 & 峰度

a. 偏度

b. 峰度

## 2.3 常用分布

### 2.3.1 离散分布

a. 泊松分布 (Poisson D)

b. 负二项分布 (帕斯卡分布)

### 2.3.2 连续分布

a. 正态分布 (必须会背! )

b. 伽马分布

C. 其他分布及性质

## 2.4 随机变量变换的分布

### 2.4.1 随机变量函数的分布

### 2.4.2 随机变量组合的分布

## 2.5 考点与典例

### 2.5.1 考点 1 分布函数的概念与性质

### 2.5.2 考点 2 随机变量的性质

### 2.5.3 考点 3 随机变量函数的分布

## 第三章 多维随机变量

### 3.1 多维随机变量及其分布

#### 3.1.1 多维随机变量的概念

#### 3.1.2 联合分布函数

a. 定义

b. 性质 (联合分布的四点性质)

#### 3.1.3 联合分布函数的形式

a. 离散变量的联合分布列

b. 连续变量联合密度函数

#### 3.1.4 常见的多维分布

a. 多项分布

b. 二元正态分布 (必须会背! )

### 3.2 边际分布与随机变量的独立性

#### 3.2.1 边际分布函数

#### 3.2.2 边际分布函数形式

a. 离散变量的边际分布列

b. 连续变量的边际密度函数

c. 常见的边际分布

#### 3.2.3 随机变量间的独立性

#### 3.2.4 多维随机变量函数的分布

### 3.3 多维随机变量的特征数

#### 3.3.1 多维随机变量函数的数字特征 (一维)

a. 数学期望

b. 一维随机变量组合的数学期望和方差运算性质

#### 3.3.2 多维随机变量之间的数字特征 (多维)

a. 协方差

b. 相关系数

### 3.4 条件分布与条件期望

3.4.1 条件分布  
a. 离散随机变量的条件分布列  
b. 连续随机变量的条件密度函数

3.4.2 条件数学期望

3.5 考点与典例

3.5.1 考点 1

数理统计的基本概念（进入统计）

总体、样本以及样本统计量

总体的定义和性质

统计量

各种由正态分布组合的出来的新分布

卡方分布

t 分布（单变量检验）

F 分布（多变量检验）

分位点（查表）

正态分布总体下的样本分布（后续很多理论知识的基础）

参数估计——由样本估计总体参数

点估计

矩估计（采用【矩】这一统计量进行估计）

极大似然估计（让看到的样本发生的概率最大化）

点估计选择估计出来的结果的标准

区间估计（一个硬币的两面）

假设检验

## 第一章 随机事件与概率

### 1.1 随机事件及其运算

所有的数学都一定是从看得见摸得着的事物出发的，概率同样也是如此，概率的直观概念就是随机事件发生的可能性大小。因此我们先研究生活中可能看到的一些随机事件，并用数学语言进行刻画，并进行相应的集合运算（交、并、补、差、互斥<一分为多>、对立<一分为二>等等），得到相关的运算法则（德摩根定率）。

$$\overline{A \cup B} = \overline{A} \cap \overline{B}$$
$$\overline{A \cap B} = \overline{A} \cup \overline{B}$$

刻画随机事件（连续 or 离散）让我们对概率所依附的实体有了直观的认识。同时也要要理解清楚样本空间的含义是什么。

**【定义】** 样本空间 and 样本点：随机现象的一切可能基本结果组成的集合成为样本空间，记为  $\Omega = \{\omega\}$ ，其中  $\omega$  表示基本结果，又称为样本点。样本点就是概率统计中抽样、计算的基本单元，认识随机现象首先要列出他的样本空间。

### 1.2 概率的定义及其确定方法

#### 1.2.1 概率的公理化定义

尽管从直观上出发，通过解释随机事件，能够给出“概率”的定义。

但是无论是哪种定义（古典、几何）方式都无法适应于一切随机现象。因此：

- 1900 年数学家 Hilbert 提出要建立概率的公理化定义，以最少的几条本质特性来刻画概率的概念。

- 1933 年 Kolmogorov 提出了如下概率的公理化定义。

设  $\Omega$  为一个样本空间， $\mathcal{F}$  为  $\Omega$  的某些子集组成的一个事件域（简单来说就是样本空间中各样本点的各种组合，因此事件域肯定包含样本空间），如果对任一事件  $A \in \mathcal{F}$ ，定义在  $\mathcal{F}$  上的一个实值函数  $P(A)$  满足：

- 非负性公理：若  $A \in \mathcal{F}$ ，则  $P(A) \geq 0$ ；
- 正则性公理： $P(\Omega) = 1$ ；
- 可列可加性公理：若  $A_1, A_2, \dots, A_n, \dots$  互不相容，有（和的概率等于概率之和）

$$P\left(\bigcup_{i=1}^{+\infty} A_i\right) = \sum_{i=1}^{+\infty} P(A_i),$$

则称  $P(A)$  为事件  $A$  的概率，称三元素  $(\Omega, \mathcal{F}, P)$  为概率空间。

可列可加性是推出一系列概率公式的出发点  $P(A + B); P(A - B) \dots$

## 1.2.2 概率的确定方法

确定了概率是什么，还需要知道概率如何计算。其实本质上讲概率的计算可以划分为两类：

- 离散型随机变量的概率计算（古典方法）
- 连续型随机变量的概率计算（几何方法）

### a. 确定概率的古典方法

对于在离散的样本空间中的有限个样本点且等可能而言，可以直接通过排列组合的方式直接计算（本质就是数点）。常见的模型有：抽样模型（放回、不放回）以及盒子模型等。

对于这类问题，计算最复杂但思维清晰的思路是（有些多情况可以不做唯一标识进行简化计算，但是思维的复杂度会增加）：

- 对样本空间内的每种情况做唯一标识，做分母
- 对符合条件的每种情况做唯一标识，做分子

#### 古典方法的例子

- 盒子模型

设有  $n$  个球，每个球都等可能地被放到  $N$  个不同的盒子中的任意一个，每个盒子所放球数不限，求：

- (1) 指定的  $n$  ( $n \leq N$ ) 个盒子中各有一球的概率  $p_1$
- (2) 恰好有  $n$  ( $n \leq N$ ) 个盒子中各有一球的概率  $p_2$

// 思路：对于这个题目而言，我们既可以把所有的球看作相同的，也可以给每个球编号看作不同的。

// 为了简化思维，最好的方式就是给每个球编号进而对样本空间的每种情况做唯一标识。

- (1)
  - 分母（全样本空间）： $n$  个球，每个球都有  $N$  中放法  $\Rightarrow n^N$ ；
  - 子分子（满足情况的点）：把  $n$  个球放到  $n$  个盒子中，而且是互斥的  $\Rightarrow n!$
  - 结果： $n! / n^N$
- (2)
  - 分母（全样本空间）不变。
  - 子分子（满足情况的点）：多了一步在  $N$  中选  $n$  个盒子的步骤，所以可能性就多了  $* C(Nn)$
  - 结果：上述结果  $* C(Nn)$

## b. 确定概率的几何方法

对于在连续的样本空间中的无限个样本点而言，无法通过直接数点的方式进行计算。常见的例子有：会面问题、比丰投针问题（算 $\pi$ ）、算函数的积分（[蒙特卡洛模拟](#)）等。

对于这类问题，思路和上述本质是一样的，不过分子分母从之前的点的数量变成了一维（线的长度），二维（面积），三维（体积）之比。

### 几何方法的例子

- [贝特朗奇论](#)

在一圆内任取一条弦，问其长度超过该圆内接等边三角形的边长的概率是多少。

针对这一个问题，有三种不同的解题思路得到三种完全不同的答案。（所占的整体立场不同，结果就会截然不同）

## 1.3 概率的性质

### 1.3.1 概率的基本性质

由概率的公理化定义可以轻松得到概率的如下性质：有限可加性、单调性。[条件概率满足一切的基本概率性质](#)。在这我们强调两个公式，因为经常用到

- 加法公式（三个事件）

$$P(A + B + C) = (P(A) + P(B) + P(C)) - (P(AB) + P(AC) + P(BC)) + P(ABC)$$

- 互斥公式

$$P(A\bar{B}\bar{C}) = P(AB) - P(ABC)$$

### 1.3.2 条件概率及其性质

#### a. 条件概率的定义

$$P(B|A) = \frac{P(AB)}{P(A)}$$

#### b. 全概率公式

$$P(B) = \sum P(A_i)P(B|A_i)$$

全概率公式是多个分散情况到集中情况的汇总：是在已经知道多个简单事件（构成完备事件组）的概率，以及在每个简单事件发生情况下复杂事件发生的条件概率的情况下，求解复杂事件所发生实际概率（积沙成塔，条条大路通罗马，不放回未知抽签）。

#### c. 贝叶斯公式

$$P(A|B) = \frac{P(A)P(B|A)}{P(B)}$$

贝叶斯公式是打开真实世界的一把钥匙。首先我们思考一个问题：[在真实世界中真的存在非条件概率吗？](#) 我个人觉得不存在，也就是说世界上所有概率本质都是条件概率，但是由于条件的错综复杂性，很难直接获得准确、真实的条件概率值，那我们就需要一步步地细化认知，怎么做呢？按照如下的方式（最经典的例子莫过于[狼来了](#)的故事，以及检查疾病的例子）。

Step 1：依靠过去的经验，对事件 A 的发生有着基本的判断 => 通过过往认知，能够得到事件 A 发生的先验概率为  $P(A)$

Step 2：但是这个先验概率可能并不是十分准确的，因为真实世界中可能根本不存在非条件概率。

A 的发生总会和其他一些事情相牵连，所以我们总会充分获取一些事情（比如 B）的相关信息来对 A 发生的概率进行调整

Step 3：计算后验概率  $P(A|B)$ ，之所以叫做后验概率就是因为实在获取 B 事件之后才调整出的概率。

Step 1 to 3 在真实世界中是不断循环往复，以获取尽可能准确的后验概率。

// ----- //

教材上讲了狼来了的故事，我们在这再补充一个检查肝癌的例子。

- 已经知道一个村子的肝癌发生概率（先验概率  $P(L)$ ），这个概率是通过过往的经验来的（比如过去 100 年一个共有多少人得了）
- 但是只有这个先验概率，我们只能得出一个结论：每个人都有  $P(L)$  的几率罹患肝癌，这个概率是没有意义的。  
因此，我们要找和肝癌相关联的事件，科学家们历经千辛万苦找到了和肝癌具有一定“因果关系”（或许只是相关关系）的一种试剂检测方式
- 这样我们就可以计算后验概率  $P(L|A)$  以及  $P(L|\sim A)$  帮助甄别肝癌患病概率。当然，这要求我们有着精确的  $P(A)$ ;  $P(A|L)$ ;  $P(A|\sim L)$ ;
  - $P(A)$  就是我们之前已经获取的不那么精准的先验概率；
  - $P(A|L)$  和  $P(A|\sim L)$  都可以通过实验得出。

### 1.3.3 独立性

#### a. 定义

通过条件概率公式我们可以推得如果一个事件 A 的先验概率  $P(A)$  等于在某事件 B 下的后验概率  $P(A|B)$ ，那么我们就说 A、B 二者独立，从直观上理解就是事件 A 的发生于事件 B 没有任何关系。更进一步地，如果满足下式子，即说明两个事件相互独立。注意，这个公式是判断事件是否独立的唯一方法，千万不要依靠直觉去判断！

$$P(AB) = P(A)P(B)$$

拓展来看（多个事件的相互独立性）：设有  $n$  个事件  $A_1, A_2, \dots, A_n$ ，对任意的  $1 \leq i < j < k \dots \leq n$ ，如果以下等式均成立

$$\begin{cases} P(A_i A_j) = P(A_i)P(A_j), \\ P(A_i A_j A_k) = P(A_i)P(A_j)P(A_k), \\ \vdots \\ P(A_1 A_2 \dots A_n) = P(A_1)P(A_2) \dots P(A_n), \end{cases}$$

则称此  $n$  个事件  $A_1, A_2, \dots, A_n$  相互独立。拿 3 个事件举例子：设  $A, B, C$  是三个随机事件，如果有

$$\begin{cases} P(AB) = P(A)P(B), \\ P(AC) = P(A)P(C), \\ P(BC) = P(B)P(C), \end{cases}$$

则只能得到  $A, B, C$  两两独立，若还有

$$P(ABC) = P(A)P(B)P(C)$$

才能得到  $A, B, C$  相互独立。

#### b. 性质

- 连锁反应：如果 A 和 B 独立，那么 A 反、B 反、A、B 的各种组合都独立不要怀疑！
- 必定独立：概率为 0 的时间以及概率为 1 的事件与任意一个事件均相互独立；
- A 和 B 相互独立，有： $P(A|B) = P(A|\bar{B}) = P(A)$ ，反之也成立；

- 互斥不一定独立，独立不一定互斥。二者本质上没有任何联系，根据公式就可以看出，只要 A 和 B 的概率同时都大于零那独立和互斥不可能同时出现。

## 1.4 考点与典例

### 1.4.1 考点（量化笔试就曾出现过考研原题）

- 随机事件的运算（本质是集合的计算以及集合关系的判断，利用各种集合运算定律<尤其是德摩根>，最简单的技巧就是画出集合的VN图）
- 古典概型排列组合，几何概型画图计算
- 有关概率的各种证明（三个概率的加法公式），尤其是条件概率的证明，是对乘法公式、贝叶斯公式的深入考察
- 全概率公式和贝叶斯公式
- 根据独立计算概率 => 伯努利古典概型

### 1.4.2 典例

- 三个事件的加法公式（千万不要嫌麻烦，硬算就是正确的道路）

设  $A, B, C$  为三个随机事件，且  $P(A) = P(B) = P(C) = \frac{1}{4}$ ,  $P(AB) = 0$ ,  $P(AC) = P(BC) = \frac{1}{12}$ , 则  $A, B, C$  中恰有一个事件发生的概率为 【 】

- (A)  $\frac{3}{4}$ . (B)  $\frac{2}{3}$ . (C)  $\frac{1}{2}$ . (D)  $\frac{5}{12}$ .

- 小题要学会举特例

假设必然事件或不可能事件，下面这道题目就可以先举 B 是不可能事件，再举 B 是必然事件

**【例 1.4】**  $A, B$  为任意两事件，则与事件  $(A - B) \cup (B - C)$  相等的事件为 【 】

- (A)  $A \cap B \cap C$ . (B)  $A \cup (B - C)$ . (C)  $(A \cup B) - C$ . (D)  $(A \cup B) - BC$ .

**【解析】** 选(D).

## 第二章 随机变量及其分布

第一章我们充分认识了随机事件的含义，但为了更好的进行数学处理，只用随机事件这一个工具来处理随机现象是不够的，因为事件始终是一种定性的表示。为了进行定量的数学处理，必须把随机现象的结果数量化，这就是引入随机变量的原因。

### 2.1 随机变量及其分布的概念

## 2.1.1 随机变量

定义在样本空间  $\Omega$  的实值函数  $X = X(\omega)$  称为随机变量，常用大写字母  $X, Y, Z$  等表示随机变量，其取值用小写字母  $x, y, z$  等表示。这表明：随机变量  $X$  是样本点  $\omega$  的一个函数。

- 函数既可以是不同样本对应不同的实数
- 函数也可以是多个样本点对应同一个实数

函数的自变量（样本点）可以是数，也可以不是数，但因变量一定是实数。随机变量定义的本质，是将随机事件的样本空间映射到实数空间上（随机事件的数量化）。更进一步地，随机变量就是对现实世界特征的抽象化，一个随机变量就可以表征样本点一个维度的特征。根据所映射的实数空间的特点，可以分为离散随机变量和连续随机变量。

注意，与微积分的变量不同，概率论中的随机变量  $X$  是一种“随机取值的变量且伴随着一个分布”，也就是说我们不仅要知道  $X$  可能取哪些值，而且还要知道取这些值的概率各是多少，更重要的我们知道取这些值的概率和肯定为 1。因此有没有分布是区分一般变量与随机变量的主要标志。

## 2.1.2 分布函数

### a. 定义

分布函数是将随机事件的概率与随机变量相连接的最直接的工具。设  $X$  是一个随机变量，对任意实数  $x$ ，称

$$F(x) = P(X \leq x)$$

为随机变量  $X$  的分布函数，且称  $X$  服从  $F(x)$ ，记为  $X \sim F(x)$ ，有时也可用  $F_X(x)$  以表明是  $X$  的分布函数（把  $X$  作为  $F$  的下标）。  
分布函数的概念核心是“累积”。

### b. 性质（分布函数的三点性质）

任一分布函数  $F(x)$  都具有如下三条基本性质：

- **单调性**： $F(x)$  是定义在整个实数轴  $(-\infty, +\infty)$  上的单调非减函数，即对任意的  $x_1 < x_2$ ，有  $F(x_1) \leq F(x_2)$ 。
- **有界性（规范性）**：对任意的  $x$ ，有  $0 \leq F(x) \leq 1$ ，且

$$\begin{aligned} F(-\infty) &= \lim_{x \rightarrow -\infty} F(x) = 0, \\ F(+\infty) &= \lim_{x \rightarrow +\infty} F(x) = 1. \end{aligned}$$

- **右连续性**： $F(x)$  是  $x$  的右连续函数，即对任意的  $x_0$ ，有

$$\lim_{x \rightarrow x_0^+} F(x) = F(x_0)$$

即

$$F(x_0 + 0) = F(x_0)$$

这也就意味着分布函数的定义域一定是左闭右开，左边的边界一定能包含进来，右边的边界一定无法包含进来（如果包含进来就说明右边界的+极限小也可以包含进来，就矛盾了）。尽管对于连续函数而言计算上都是相等的，但是概念上千万不可以错。

以上三条性质都可以从定义直接推出（因为定义中包含概率，所以可以借助概率的三条公理）。需要注意的是，**这三条基本性质是判断某个函数是否能成为分布函数的充要条件**。下面我们就具体来看一下，随机变量的分布函数的形式。

## 2.1.3 分布函数的形式

### a. 离散变量的分布列

对于离散变量而言，其所有可能的取值都是可列的，因此通过直接进行穷举就可以得到之前固有的概率表示形式，称之为分布列。其能够直观地表现出概率的大小关系，直接显示出哪些地方概率大，哪些地方概率小。

|     |          |          |   |          |   |
|-----|----------|----------|---|----------|---|
| $X$ | $x_1$    | $x_2$    | … | $x_n$    | … |
| $P$ | $p(x_1)$ | $p(x_2)$ | … | $p(x_n)$ | … |

根据定义，我们也可以直接得到离散随机变量的分布函数

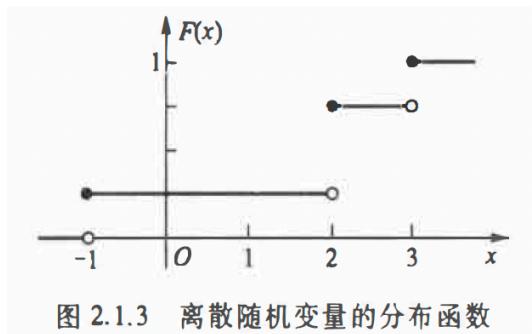


图 2.1.3 离散随机变量的分布函数

从这个地方我们就可以看出来，离散随机变量的分布列和分布函数都可以直接从概率推出来，二者之间并没有衍生关系。

### b. 连续变量的概率密度函数

对连续变量而言，其所有可能的取值不可列，只能在数轴上进行连续地呈现，不存在分布列的概念，因此给出如下定义：设随机变量  $X$  的分布函数为  $F_X(x)$ ，如果存在实数轴上的一个非负可积函数  $p(x)$ ，使得对任意实数  $x$  有

$$F(x) = \int_{-\infty}^x p(t)dt,$$

则称  $p(x)$  为  $X$  的概率密度函数，进而我们可以得到，在  $F(x)$  存在导数的点上：

$$p(x) = F'(x)$$

因此概率密度函数是分布函数的一种衍生概念。概率密度函数的两大性质：

- 非负性：始终  $\geq 0$
- 正则性：积分为 1

通过引入概率密度函数的概念，采用图形的面积直观展现概率大小，能够达到类似于分布列的效果，但在其本质含义上天差地别：离散随机变量  $X$  在其可能取值的点  $x_1, x_2, \dots, x_n, \dots$  上的概率不为 0，而连续随机变量  $X$  在  $(-\infty, +\infty)$  上任一点  $a$  的概率恒为 0

$$P(X = a) = \int_a^a p(x)dx = 0$$

这表明：

- 不可能事件的概率为 0，但概率为 0 的事件不一定是不可能事件（一个点）
- 必然事件的概率为 1，但概率为 1 的事件不一定是必然事件（连续样本空间挖掉一个点）

这也进一步呈现出了概率论和微积分的不同之处，在有限个点上（概率为 0 的部分）做操作对函数的性质没有任何的影响，也就是说在概率论中可以剔除概率为 0 的事件后讨论两个函数相等以及其他随机问题。

## 2.2 随机变量的数字特征

### 2.2.1 $k$ 阶矩

设  $X$  为随机变量,  $k$  为正整数。如果以下的数学期望都存在, 则称

- $\mu_k = E(X^k)$  为  $X$  的  $k$  阶原点矩;
- $\nu_k = E[X - E(X)]^k$  为  $X$  的  $k$  阶中心矩。

可以看出, 这是对随机变量基本数据特征的汇总, 后续所有的数字特征都是通过这个概念衍生出来的, 所谓矩就是距离。

### 2.2.2 数学期望 (1 阶原点矩)

#### a. 定义

数学期望的本质是随机变量的值通过与概率的大小 (发生的可能性) 进行加权平均, 表示分布所处位置的特征数, 刻画了  $X$  的取值始终在  $E(x)$  的周围波动, 进而在一定程度上消除随机变量的随机性。

针对离散和连续随机变量有不同的表述形式, 但是其本质含义是相通的。我们在此给出连续随机变量的期望定义, 离散随机变量只需将积分变为级数求和。设连续随机变量  $X$  的密度函数为  $p(x)$ , 如果

$$\int_{-\infty}^{+\infty} |x| p(x) dx < +\infty$$

则称

$$E(X) = \int_{-\infty}^{+\infty} x p(x) dx$$

为  $X$  的数学期望, 或称为该分布  $p(x)$  的数学期望, 简称期望或均值。若  $\int_{-\infty}^{+\infty} |x| p(x) dx$  不收敛, 则称  $X$  的数学期望不存在。

#### b. 性质

数学期望的核心性质为如下, **这个性质能够让我们在不求出随机变量  $g(X)$  的分布的情况下求解出其均值:** (该定理较难证明)

$$E[g(X)] = \begin{cases} \sum_i g(x_i)p(x_i), & \text{在离散场合;} \\ \int_{-\infty}^{+\infty} g(x)p(x)dx, & \text{在连续场合.} \end{cases}$$

当然, 这并不意味着所有随机变量函数的均值都要这么求, 因为如果相乘后求积分很困难的话, 我们还是需要用两步骤法:

- **Step 1** 求解出随机变量  $g(X)$  的分布
- **Step 2** 根据分布直接计算均值

依据该重要性质, 我们可以推导出:

- $E(c) = c$
- $E(aX) = aE(X)$

## 2.2.3 方差 & 标准差 (2 阶中心矩)

### a. 定义

方差的本质是随机变量的值与期望的差的平方（离散程度）的期望，表示随机变量的波动程度。若随机变量  $X^2$  的数学期望  $E(X^2)$  存在，则称偏差平方  $(X - E(X))^2$  的数学期望  $E(X - E(X))^2$  为随机变量  $X$ （或相应分布）的方差，记为：

$$Var(X) = E(X - E(X))^2 = \begin{cases} \sum_i [x_i - E(X)]^2 p(x_i), & \text{在离散场合;} \\ \int_{-\infty}^{+\infty} [x - E(X)]^2 p(x) dx, & \text{在连续场合.} \end{cases}$$

称方差的正平方根  $\sqrt{Var(X)}$  为随机变量  $X$ （或相应分布）的标准差，记为  $\sigma(X)$ ，或  $\sigma_X$ 。需要注意的是：如果随机变量  $X$  的数学期望存在，其方差不一定存在；而当  $X$  的方差存在时，则  $E(X)$  必定存在，其原因在于  $|x| \leq x^2 + 1$  总是成立的。

### b. 性质

- $Var(X) = E(X^2) - [E(X)]^2$  求解方差的常用方法。
- $Var(c) = E(c - E(c))^2 = E(c - c)^2 = 0$
- $Var(aX + b) = a^2 Var(X)$

### c. 切比雪夫不等式

世间万物均有回归现象，随机变量其本质也是趋近于均值的回归，与均值偏差较大的事件发生的概率可能性要更小。因此随机变量的可能取值、均值以及方差之间存在一个很显然的不等式来表示这种回归约束，这就是切比雪夫不等式的现实含义。

设随机变量  $X$  的数学期望和方差都存在，则对任意常数  $\varepsilon > 0$ ，有：

$$P(|X - E(X)| \geq \varepsilon) \leq \frac{Var(X)}{\varepsilon^2}$$

更进一步的解释如下：在概率论中，事件“ $|X - E(X)| \geq \varepsilon$ ”称为大偏差，其概率  $P(|X - E(X)| \geq \varepsilon)$  称为大偏差发生概率，切比雪夫不等式给出大偏差发生概率的上界，这个上界与方差成正比，方差愈大上界也愈大，方差愈小随机变量的取值更加集中在均值附近。

## 2.2.3 变异系数

方差（或标准差）反映了随机变量取值的波动程度，但在比较两个随机变量的波动大小时，如果仅看方差（或标准差）的大小有时会产生不合理的现象。这有两个原因（说白了就是因为绝对的大小进行比较没有任何实际意义）

- 随机变量的取值有量纲，不同量纲的随机变量用其方差（或标准差）去比较它们的波动大小不太合理
- 在取值的量纲相同的情况下，取值的大小有一个相对性问题，取值较大的随机变量的方差（或标准差）也允许大一些

所以要比较两个随机变量的波动大小时，在有些场合使用以下定义的变异系数来进行比较，更具可比性。设随机变量  $X$  的二阶矩存在，则称比值

$$C_v(X) = \frac{\sqrt{Var(X)}}{E(X)} = \frac{\sigma(X)}{E(X)}$$

为  $X$  的变异系数。因为变异系数是以其数学期望为单位去度量随机变量取值波动程度的特征数，标准差的量纲与数学期望的量纲是一致的，所以变异系数是一个无量纲的量。

## 2.2.4 分位数 ( $p$ 值、中位数)

设连续随机变量  $X$  的分布函数为  $F(x)$ , 密度函数为  $p(x)$ , 对任意  $p \in (0, 1)$ , 称满足条件

$$F(x_p) = \int_{-\infty}^{x_p} p(x)dx = p$$

的  $x_p$  为此分布的  $p$  分位数, 又称下侧  $p$  分位数。

## 2.2.5 偏度 & 峰度

这两个特征数是描述分布形状的特征数, 本质是相对特征, 都是标准正态分布为基准。标准正态分布的偏度和峰度都是 0。在实际中, 一个分布标准化后的偏度和峰度皆为 0 或近似为 0 时, 常认为该分布为正态分布或近似为正态分布。

### a. 偏度

设随机变量  $X$  的三阶矩存在, 则称比值

$$\beta_s = \frac{E[X - E(X)]^3}{[E(X - E(X))^2]^{3/2}} = \frac{\nu_3}{(\nu_2)^{3/2}}$$

为  $X$  的分布的偏度系数 (偏度), 是描述分布偏离对称程度的一个特征数。

- 当  $\beta_s > 0$  时, 分布为正偏或右偏
- 当  $\beta_s = 0$  时, 分布关于其均值  $E(X)$  对称
- 当  $\beta_s < 0$  时, 分布为负偏或左偏

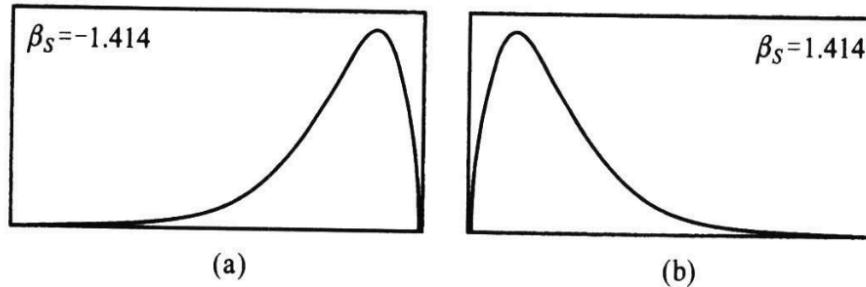


图 2.7.3 两个密度函数,(a)为左偏,(b)为右偏

### b. 峰度

设随机变量  $X$  的四阶矩存在, 则称比值

$$\beta_k = \frac{E[X - E(X)]^4}{[E(X - E(X))^2]^2} - 3 = \frac{\nu_4}{(\nu_2)^2} - 3$$

为  $X$  的分布的峰度系数, 是描述分布尖锐程度和尾部粗细的一个特征数, 注意不是分布的峰值高低 (稍加计算就会发现正态分布的峰度和其峰值完全无关)。

- 当  $\beta_k < 0$  时, 则标准化后的分布尖锐程度比标准正态分布更平坦, 称为低峰度
- 当  $\beta_k = 0$  时, 则标准化后的分布尖锐程度与标准正态分布相当
- 当  $\beta_k > 0$  时, 则标准化后的分布尖锐程度比标准正态分布更尖峭, 称为高峰度

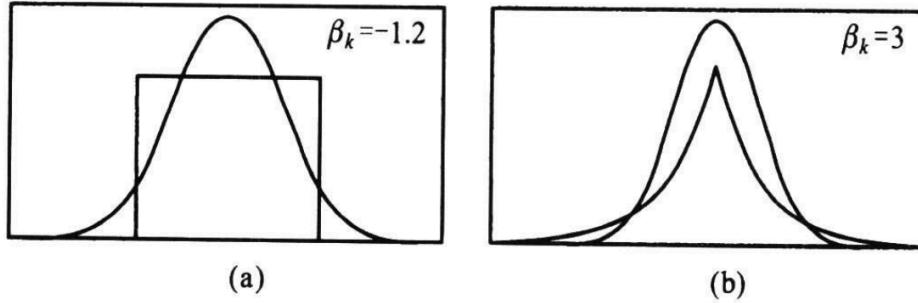


图 2.7.4 两个密度函数与标准正态分布密度函数的比较

它们的均值相等、方差相等、偏度皆为 0(对称分布), 而峰度有很大差别

## 2.3 常用分布

通过对现实世界的观察, 可以总结发现很多常见的分布, 在此对概念和常用性质做一个总结, 需要经常进行记忆。后面则细化补充说明了一些常见分布的特点, 并辅之以相关题目。

表 2.5.1 常用概率分布及其数学期望和方差

| 分 布                        | 分布列 $p_k$ 或分布密度 $p(x)$  | 期 望             | 方 差                             |
|----------------------------|---|-----------------|---------------------------------|
| 0-1 分布                     | $p_k = p^k (1-p)^{1-k}$ , $k=0,1$   | $p$             | $p(1-p)$                        |
| 二项分布<br>$b(n,p)$           | $p_k = \binom{n}{k} p^k (1-p)^{n-k}$ , $k=0,1,\dots,n$  | $np$            | $np(1-p)$                       |
| 泊松分布<br>$P(\lambda)$       | $p_k = \frac{\lambda^k}{k!} e^{-\lambda}$ , $k=0,1,\dots$   | $\lambda$       | $\lambda$                       |
| 超几何分布<br>$h(n,N,M)$        | $p_k = \frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}}$ , $k=0,1,\dots,r$ ,<br>$r=\min\{M,n\}$             | $n \frac{M}{N}$ | $\frac{nM(N-M)(N-n)}{N^2(N-1)}$ |
| 几何分布<br>$Ge(p)$            | $p_k = (1-p)^{k-1} p$ , $k=1,2,\dots$   | $\frac{1}{p}$   | $\frac{1-p}{p^2}$               |
| 负二项分布<br>$Nb(r,p)$         | $p_k = \binom{k-1}{r-1} (1-p)^{k-r} p^r$ , $k=r,r+1,\dots$  | $\frac{r}{p}$   | $\frac{r(1-p)}{p^2}$            |
| 正态分布<br>$N(\mu, \sigma^2)$ | $p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}$ , $-\infty < x < \infty$ | $\mu$           | $\sigma^2$                      |
| 均匀分布<br>$U(a,b)$           | $p(x) = \frac{1}{b-a}$ , $a < x < b$  | $\frac{a+b}{2}$ | $\frac{(b-a)^2}{12}$            |

续表

| 分布                            | 分布列 $p_k$ 或分布密度 $p(x)$  | 期望  | 方差  |
|-------------------------------|---|---|---|
| 指数分布<br>$Exp(\lambda)$        | $p(x) = \lambda e^{-\lambda x}, \quad x \geq 0$   | $\frac{1}{\lambda}$                       | $\frac{1}{\lambda^2}$   |
| 伽马分布<br>$Ga(\alpha, \lambda)$ | $p(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, \quad x \geq 0$                | $\frac{\alpha}{\lambda}$                  | $\frac{\alpha}{\lambda^2}$  |
| $\chi^2(n)$ 分布                | $p(x) = \frac{x^{n/2-1} e^{-x/2}}{\Gamma(n/2) 2^{n/2}}, \quad x \geq 0$                                   | $n$                                       | $2n$  |
| 贝塔分布<br>$Be(a, b)$            | $p(x) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1} (1-x)^{b-1}, \quad 0 < x < 1$                      | $\frac{a}{a+b}$                           | $\frac{ab}{(a+b)^2(a+b+1)}$   |
| 对数正态分布<br>$LN(\mu, \sigma^2)$ | $p(x) = \frac{1}{\sqrt{2\pi}\sigma x} \exp\left\{-\frac{(\ln x - \mu)^2}{2\sigma^2}\right\}, \quad x > 0$ | $e^{\mu + \sigma^2/2}$                    | $e^{2\mu + \sigma^2}(e^{\sigma^2} - 1)$   |
| 柯西分布<br>$Cau(\mu, \lambda)$   | $p(x) = \frac{1}{\pi} \frac{\lambda}{\lambda^2 + (x-\mu)^2}, \quad -\infty < x < \infty$                  | 不存在                                       | 不存在   |
| 韦布尔分布                         | $p(x) = F'(x), \quad F(x) = 1 - \exp\left\{-\left(\frac{x}{\eta}\right)^m\right\}, \quad x > 0$           | $\eta \Gamma\left(1 + \frac{1}{m}\right)$ | $\eta^2 \left[ \Gamma\left(1 + \frac{2}{m}\right) - \Gamma^2\left(1 + \frac{1}{m}\right) \right]$ |

注: 表中仅列出各分布密度函数的非零区域.

### 2.3.1 离散分布

#### a. 泊松分布 (Poisson D)

泊松分布能对现实中的许多现象进行准确描述: 常与单位时间 (或单位面积、单位产品等) 上的计数过程相联系

- 在一天内来到某商场的顾客数 (可用于排队论的假设)
- 一平方米内, 玻璃上的气泡数
- 一定时期内, 放射性物质放出的粒子数

泊松定理 (二项分布的近似) : 在  $n$  重伯努利试验中, 记事件  $A$  在一次试验中发生的概率为  $p_n$  (与试验次数  $n$  有关), 如果当  $n \rightarrow +\infty$  时, 有  $np_n \rightarrow \lambda$ , 则

$$\lim_{n \rightarrow +\infty} C_n^k p_n^k (1 - p_n)^{n-k} = \frac{\lambda^k}{k!} e^{-\lambda}.$$

这样在试验次数  $n$  很大, 而发生概率  $p$  很小的情况下, 就可以将二项分布近似为泊松分布实现简化计算。

## b. 负二项分布（帕斯卡分布）

定义：在伯努利试验序列中，记每次试验中事件  $A$  发生的概率为  $p$ ，如果  $X$  为事件  $A$  第  $r$  次出现时的试验次数，则  $X$  的可能取值为  $r, r+1, \dots, r+m, \dots$ 。称  $X$  服从负二项分布，其分布列为

$$P(X = k) = C_{k-1}^{r-1} p^r (1-p)^{k-r}, \quad k = r, r+1, \dots$$

记为  $X \sim Nb(r, p)$ ，当  $r = 1$  时，即为几何分布（几何分布具有无记忆性）。

## 2.3.2 连续分布

### a. 正态分布（必须会背！）

$X \sim N(\mu, \sigma)$  概率密度函数（配方、除系数、加因子）如下。积分得到的分布函数是算不出来的，只有趋近于正无穷 = 1 才有意义。

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

大多数时间都是只分析标准正态分布，标准正态分布的均值和方差是可以积分出来的，进而得到普通正态分布的均值方差，借助这一特殊积分，我们就可以计算如下的积分形式了

$$\int_{-\infty}^{+\infty} e^{ax^2} dx$$

### b. 伽马分布

伽马函数：

$$\Gamma(\alpha) = \int_0^{+\infty} x^{\alpha-1} e^{-x} dx$$

两大性质，辅助求解积分

- $\Gamma(1) = 1, \Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$ ;
- $\Gamma(\alpha + 1) = \alpha\Gamma(\alpha)$ （可用分部积分法证得）。当  $\alpha$  为自然数  $n$  时，有  $\Gamma(n + 1) = n\Gamma(n) = n!$

## C. 其他分布及性质

指数分布无记忆性  $P(X > a + b | a) = P(X > b)$ ，例如：学了 10 小时的情况下再学 5 个小时的概率 = 刚开始就学 5 个小时的概率。

## 2.4 随机变量变换的分布

### 2.4.1 随机变量函数的分布

设  $y = g(x)$  是定义在直线上的一个函数， $X$  是一个随机变量，那么  $Y = g(X)$  作为  $X$  的函数，同样也是一个随机变量。我们要研究的问题是：已知随机变量  $X$  的分布，如何求出另一个随机变量  $Y = g(X)$  的分布。对于离散和连续变量，其本质都是一样的，无非就是按照分布函数的定义进行推导，只不过离散变量比较简单直接求解，连续变量在某些情况下存在特殊法则。

一般情况下直接采用下面的方式对随机变量函数的分布进行求解：

- **Step 0** 确定区间范围：画图观察  $X$  和  $Y$  之间的关系，找到关键点，进而确定区间【左闭右开】！
- **Step 1** 严格按照定义进行推导

$$\begin{aligned}
F_Y(y) &= P\{Y \leq y\} \\
&= P\{g(X) \leq y\} \\
&= P\{\phi(y) \leq X \leq \gamma(y)\} \text{ 反解 } X \text{ 时需要划分好区间}
\end{aligned}$$

- **Step 2** 根据定义完成积分求出  $F_Y(y)$

$$F_Y(y) = \iint_{g(X) \leq y} f_X(x) dx = \int_{\phi(y)}^{\gamma(y)} f_X(x) dx = F_X(\gamma(y)) - F_X(\phi(y))$$

- **Step 3**  $F_Y(y)$  对  $y$  求导得到  $f_Y(y)$

$$f_Y(y) = \frac{dF_Y(y)}{dy}$$

来一个例子：正态分布标准化的过程。已知： $X \sim N(\mu, \sigma)$  证明  $Y = \frac{X-\mu}{\sigma} \sim N(0, 1)$

- **Step 1** 严格按照定义进行推导

$$\begin{aligned}
F_Y(y) &= P\{Y \leq y\} \\
&= P\left\{\frac{X-\mu}{\sigma} \leq y\right\} \\
&= P\{X \leq \sigma y + \mu\}
\end{aligned}$$

- **Step 2** 积分求出  $F_Y(y)$

$$F_Y(y) = \int_{-\infty}^{\sigma y + \mu} f_X(x) dx$$

- **Step 3**  $F_Y(y)$  对  $y$  求导得到  $f_Y(y)$

$$f_Y(y) = \frac{dF_Y(y)}{dy} = \sigma f_X(\sigma y + \mu) = \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}}$$

## 2.4.2 随机变量组合的分布

上面我们求解的是一个随机变量函数变换后的分布情况，但还有另一种情况，那就是随机变量组合的情况。例如  $N$  个独立的  $0 - 1$  分布随机变量  $X_1, X_2, \dots, X_N$  的加和  $Y = \sum_{i=1}^N X_i$  就服从二项分布。

这也就自然地引出了后续要探讨的多维随机变量分布的学习，以及对世界上各种随机事件组合出新事件的深入思考。

## 2.5 考点与典例

### 2.5.1 考点 1 分布函数的概念与性质

1 判断某些函数是否为分布函数，就是考察定义：1) 单调性；2) 两端 0 和 1；3) 右连续。

(1) 假设连续函数  $F(x)$  是分布函数且  $F(0) = 0$ ，则下列函数也为分布函数的是

$$(A) G_1(x) = \begin{cases} 1 - F\left(\frac{1}{x}\right), & x > 1, \\ 0, & x \leq 1. \end{cases} \quad (B) G_2(x) = \begin{cases} 1 + F\left(\frac{1}{x}\right), & x > 1, \\ 0, & x \leq 1. \end{cases}$$

$$(C) G_3(x) = \begin{cases} F(x) - F\left(\frac{1}{x}\right), & x > 1, \\ 0, & x \leq 1. \end{cases} \quad (D) G_4(x) = \begin{cases} F(x) + F\left(\frac{1}{x}\right), & x > 1, \\ 0, & x \leq 1. \end{cases}$$

【c】 右连续直接秒

2 根据分布函数求解概率，或者根据概率求解分布函数（套定义，得到公式）

**【例 2.4】** 假设随机变量  $X$  的绝对值不大于 1,  $P\{X = -1\} = \frac{1}{8}$ ,  $P\{X = 1\} = \frac{1}{4}$ ; 在事件  $\{-1 < X < 1\}$  出现的条件下,  $X$  在  $(-1, 1)$  内的任一子区间上取值的条件概率与该子区间长度成正比. 试求  $X$  的分布函数  $F(x) = P\{X \leq x\}$ .

三步走即可：1. 找到关键点  $(-1, 1)$  2. 划分区间 (牢记左闭右开<否则区间没有意义>) 3. 累积求和

## 2.5.2 考点 2 随机变量的性质

1. 对离散性随机变量进行判断（下面这道题必须要记住）

设  $X \sim P(\lambda)$ ,  $P_1$ ,  $P_2$  分别为随机变量  $X$  取偶数和奇数的概率, 则 ( )



这道题的求解太 amzing 了，感觉随时都有可能考到，这也说明了高数的重要性

- **Step 1** 给出泊松分布  $P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$
  - **Step 2** 给出取偶数的概率  $P(X = k | k \text{ 为偶数}) = \sum_{i=0}^n \left( \frac{\lambda^{2i}}{2i!} e^{-\lambda} \right) = e^{-\lambda} \sum_{i=0}^n \frac{\lambda^{2i}}{2i!}$
  - **Step 3** 想方设法求解后面的级数，想到泰勒展开

- $e^x = \sum_{i=0}^n \frac{x^i}{i!}$
- $e^{-x} = \sum_{i=0}^n \frac{(-x)^i}{i!}$
- $e^x + e^{-x} = \sum_{i=0}^n \frac{2x^{2i}}{2i!}$  所有偶数项的二倍
- $e^x - e^{-x} = \sum_{i=0}^n \frac{2x^{(2i+1)}}{(2i+1)!}$  所有奇数项的二倍

因此  $e^{-\lambda} \sum_{i=0}^n \frac{\lambda^{2i}}{2i!} = e^{-\lambda} \left( \frac{e^\lambda + e^{-\lambda}}{2} \right) > \frac{1}{2}$

(c) 为偶数的概率大于 0.5，所以为偶数的概率大于为奇数的概率

2. 连续随机变量的概率密度函数，和判断分布函数一样的意思。直接套定义，1) 始终大于等于 0；2) 积分为 1

设随机变量  $X$  的概率密度为  $f(x)$ , 则下列可以作为概率密度的是 ( )  
 (A)  $f(2x)$ . (B)  $f(2-x)$ . (C)  $f^2(x)$ . (D)  $f(x^2)$ .

3. 指数分布的考点，最直接的考点就是：指数分布的定义

【例 2.19】假设一大型设备在任何长为  $t$  的时间内发生故障的次数  $N(t)$  服从参数为  $\lambda t$  的泊松分布.

- (I) 求相继两次故障之间时间间隔  $T$  的概率分布;  
(II) 求在设备已经无故障工作 8 小时的情况下, 继续无故障运行 8 小时的概率  $Q$ .

$$F_T(t) = P\{T \leq t\} = 1 - P\{N(t) = 0\} \quad (\text{在 } t \text{ 时间内不发生故障的概率})$$

【定义题 + 智力题】只要弄清楚概率分布函数的定义并灵活转换即可 + 指数分布的无记忆性

4. 正态分布辅助计算积分, 实际上带  $e^{x^2}$  的积分直接求都是不可求的, 遇到之后都要借助标准正态分布, 永远记住: 不标准的正态分布根本没办法求解, 所有关于正态分布的计算都要标准化。

(7) 设  $f(x) = ke^{-x^2+2x-3} (-\infty < x < +\infty)$  是某分布的概率密度, 则  $k = \underline{\hspace{2cm}}$ .

### 2.5.3 考点 3 随机变量函数的分布

这一类题目数不胜数, 二维变量也是常见的, 我们在前面的知识点处已经梳理了整体的思路, 做题用下述步骤

1. 画图, 找到  $x$  和  $g(x)$  的图像关系
2. 找关键点, 划分区间 (划分区间是最重要的, 左闭右开)
3. 套用定义完成计算 (step 1、2、3 走下去)

设随机变量  $X$  的概率密度为  $f_X(x) = \begin{cases} 3e^{-3x}, & x \geq 0, \\ 0, & x < 0, \end{cases}$  求随机变量

$Y = \begin{cases} (X-1)^2 - 1, & X \geq 0 \\ -X, & X < 0 \end{cases}$  的分布函数  $F_Y(y)$ .

划分准区间为:  $(-\infty, -1), [-1, 0), [0, +\infty)$

设随机变量  $X$  的概率密度为  $f(x) = \frac{e^x}{(1+e^x)^2}, -\infty < x < +\infty$ , 令  $Y = e^x$ ,

- (1) 求  $X$  的分布函数;
- (2) 求  $Y$  的概率密度函数;
- (3)  $Y$  的期望是否存在?

## 第三章 多维随机变量

如在一维随机变量中所提的那样，随机变量是对某个样本空间下的样本点特征的描述。在实际随机现象中，对样本空间  $\Omega$  里的每个样本点  $\omega$  而言，只用一个随机变量取描述他的特征是完全不够的。比如要研究西瓜的分类，对西瓜群这一样本空间下的每个西瓜而言，只研究样本点的体积  $X(\omega)$  或者样本点的质量  $Y(\omega)$  又或者样本点的密度  $Z(\omega)$  这些个单一变量，从某个局部特征刻画西瓜，往往是不全面的。实际上，我们应该把这些随机变量所代表的特征作为一个整体联合考虑：

- 一方面，讨论这些特征同时变化的统计规律性，进而从整体上更好地表征样本特点
- 另一方面，也可以讨论多个变量之间的关系，发现特征之间相互的的统计规律性

因此，可以看出研究现实世界更多依靠的是多维随机变量，需要从多个维度全面综合地考虑某一样本点的整体特征。

所以这一章我们先引入了多维随机变量的概念，诠释了什么是联合分布函数（3.1节）。进而站在数理化的角度上，通过发掘二维联合分布函数以下三个方面的信息，达到全面理解样本特征的目的

- 每个分量的分布（每个分量单独表达的所有信息），即边际分布（3.2）
- 分量之间的关联程度，即协方差和相关系数；以及分量对整体的表征能力，即对多维变量进行函数替换后的均值（3.3）
- 大多数多维随机变量之间并非独立的，需要研究这种相依性。给定一个分量时，另一个分量的分布，即条件分布（3.4）

## 3.1 多维随机变量及其分布

这一部分的相关概念和定义，完全对照一维变量的进行对称理解。

### 3.1.1 多维随机变量的概念

多维随机变量的概念是从一维衍生出来的：如果  $X_1(\omega), X_2(\omega), \dots, X_n(\omega)$  是定义在同一样本空间  $\Omega = \{\omega\}$  上的  $n$  个随机变量，则称

$$X(\omega) = (X_1(\omega), X_2(\omega), \dots, X_n(\omega))$$

为  $n$  维（或  $n$  元）随机变量。注意，多维随机变量的关键是定义在同一样本空间上（都研究人或骰子的特征），对于不同样本空间上的两个随机变量（同时研究人和骰子），我们只能在乘积空间  $\Omega_1 \times \Omega_2 = \{(\omega_1, \omega_2); \omega_1 \in \Omega_1, \omega_2 \in \Omega_2\}$  上讨论。而在现实实际问题中，我们往往都是对同一样本空间进行研究，比如做线性回归时，所有的解释变量基本都来自于一个样本空间：

- 在研究四岁至六岁儿童的生长发育情况时，我们感兴趣于每个儿童（样本点  $\omega$ ）的身高  $X_1(\omega)$  和体重  $X_2(\omega)$ 。这里  $(X_1, X_2)$  是一个二维随机变量。
- 在研究每个人的教育回报率的，我们感兴趣每个人（样本点  $\omega$ ）的教育时间  $X_1(\omega)$ 、工作时间  $X_2(\omega)$ 、性别  $X_3(\omega)$ 、年龄  $X_4(\omega)$ ，则  $(X_1, X_2, X_3, X_4)$  就是一个四维随机变量。

### 3.1.2 联合分布函数

#### a. 定义

不可置否，多维随机变量中的每一个随机变量都可以使用一维随机变量的理论进行研究。但是我们更需要探索出多维随机变量联合起来的特点，就必须依靠联合分布函数完成刻画。对任意的  $n$  个实数  $x_1, x_2, \dots, x_n$ ，则  $n$  个事件  $\{X_1 \leq x_1\}, \{X_2 \leq x_2\}, \dots, \{X_n \leq x_n\}$  同时发生的概率：

$$F(x_1, x_2, \dots, x_n) = P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n)$$

称为  $n$  维随机变量  $(X_1, X_2, \dots, X_n)$  的联合分布函数。

在二维随机变量  $(X, Y)$  场合，联合分布函数  $F(x, y) = P(X \leq x, Y \leq y)$  是事件  $\{X \leq x\}$  与  $\{Y \leq y\}$  同时发生（交）的概率。如果将二维随机变量  $(X, Y)$  看成是平面上随机点的坐标，那么联合分布函数  $F(x, y)$  在  $(x, y)$  处的函数值就是随机点  $(X, Y)$  落在以  $(x, y)$  为右上角的无穷矩形内的概率。有时为了更加直观我们将  $F(x, y)$  记作  $F_{X,Y}(x, y)$ 。

## b. 性质 (联合分布的四点性质)

任一二维联合分布函数  $F(x, y)$  必具有如下四条基本性质 (和分析多变量函数一样, 该函数的特征往往是通过每个变量来体现的) :

- **单调性:**  $F(x, y)$  分别对  $x$  或  $y$  是单调不减的, 即
  - 当  $x_1 < x_2$  时, 有  $F(x_1, y) \leq F(x_2, y)$
  - 当  $y_1 < y_2$  时, 有  $F(x, y_1) \leq F(x, y_2)$
- **有界性 (规范性) :** 对任意的  $x$  和  $y$ , 有  $0 \leq F(x, y) \leq 1$ , 且

$$\begin{aligned}F(-\infty, y) &= \lim_{x \rightarrow -\infty} F(x, y) = 0, \\F(x, -\infty) &= \lim_{y \rightarrow -\infty} F(x, y) = 0, \\F(+\infty, +\infty) &= \lim_{x, y \rightarrow +\infty} F(x, y) = 1.\end{aligned}$$

- **右连续性:** 对每个变量都是右连续的, 即

$$\begin{aligned}F(x+0, y) &= F(x, y), \\F(x, y+0) &= F(x, y).\end{aligned}$$

- **非负性:** 对任意的  $a < b, c < d$  有 (夹缝概率大于等于 0)

$$P(a < X \leq b, c < Y \leq d) = F(b, d) - F(a, d) - F(b, c) + F(a, c) \geq 0.$$

同一维变量这四条性质也是充分必要条件。二维变量的前三点性质可以从概率的定义出发推出, 而第四条是二维变量特有的 (当然也是显然的)。注意前三条并不能推出第四条, 存在满足前三条但不满足第四条的联合分布函数:

$$G(x, y) = \begin{cases} 0, & x + y < 0; \\ 1, & x + y \geq 0 \end{cases}$$

### 3.1.3 联合分布函数的形式

#### a. 离散变量的联合分布列

对于二维离散变量而言, 每个点仍然是可列的, 因此我们可以直观地对离散变量的每个点进行概率计算得到**联合分布列**, 如果二维随机变量  $(X, Y)$  只取有限个或可列个数对  $(x_i, y_j)$ , 则称  $(X, Y)$  为**二维离散随机变量**, 称

$$p_{ij} = P(X = x_i, Y = y_j), \quad i, j = 1, 2, \dots$$

为  $(X, Y)$  的**联合分布列**。分析联合分布列一般都是画一个二维的表格, 比较直观。

#### b. 连续变量联合密度函数

根据分布函数的概念, 可以衍生出直观描述连续变量概率分布情况的**联合密度函数**。如果存在二元非负函数  $p(x, y)$ , 使得二维随机变量  $(X, Y)$  的分布函数  $F(x, y)$  可表示为

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y p(u, v) dv du$$

称  $p(u, v)$  为  $(X, Y)$  的**联合密度函数**。反过来, 在  $F(x, y)$  偏导数存在的点上有

$$p(x, y) = \frac{\partial^2}{\partial x \partial y} F(x, y).$$

联合密度函数两条基本性质不变（非负性 + 正则性）。联合密度函数的直观理解是使用体积衡量概率大小，因此在计算某一个区域的概率时，就是求出这一部分函数所成的体积大小，也就是求出联合密度函数在这一区域内的二重积分。

### 3.1.4 常见的多维分布

#### a. 多项分布

进行  $n$  次独立重复试验，如果每次试验有  $r$  个可能结果： $A_1, A_2, \dots, A_r$ ，且每次试验中  $A_i$  发生的概率为  $p_i = P(A_i), i = 1, 2, \dots, r$  且  $p_1 + p_2 + \dots + p_r = 1$ ，记  $X_i$  为  $n$  次独立重复试验中  $A_i$  出现的次数，则  $(X_1, X_2, \dots, X_r)$  取值  $(n_1, n_2, \dots, n_r)$  的概率，即  $A_1$  出现  $n_1$  次， $A_2$  出现  $n_2$  次…… $A_r$  出现  $n_r$  次的概率为

$$\begin{aligned} P(X_1 = n_1, X_2 = n_2, \dots, X_r = n_r) &= C_n^{n_1} C_{n-n_1}^{n_2} C_{n-n_1-n_2}^{n_3} \cdots C_{n_r}^{n_r} p_1^{n_1} p_2^{n_2} \cdots p_r^{n_r} \\ &= \frac{n!}{n_1! n_2! \cdots n_r!} p_1^{n_1} p_2^{n_2} \cdots p_r^{n_r} \end{aligned}$$

其中  $n = n_1 + n_2 + \dots + n_r$ ，这个联合分布列被称为  $r$  项分布，又称为多项分布。显然， $r$  项分布中只有  $r - 1$  个随机变量！

#### b. 二元正态分布（必须会背！）

如果二维随机变量  $(X, Y)$  的联合密度函数为：

$$p(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[ \frac{(x-\mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2} \right] \right\},$$

其中  $-\infty < x, y < +\infty$ ，则称  $(X, Y)$  服从二元正态分布，记为  $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 。其中五个参数的取值范围分别是：

$$-\infty < \mu_1, \mu_2 < +\infty; \quad \sigma_1, \sigma_2 > 0; \quad -1 \leq \rho \leq 1.$$

$\mu_1, \mu_2$  分别是  $X$  与  $Y$  的均值， $\sigma_1^2, \sigma_2^2$  分别是  $X$  与  $Y$  的方差， $\rho$  是  $X$  与  $Y$  的相关系数。

## 3.2 边际分布与随机变量的独立性

正如之前提到的那样，要想诠释真实世界往往需要直接引入多维随机变量展开研究。但是多维随机变量中的每个分量可能也存在某些性质需要发掘，这个时候我们就需要对多维随机变量进行降维，或者说进行维度压缩，这时候就需要用到边际分布了。

### 3.2.1 边际分布函数

边际分布函数的本质是进行维度压缩（消除一个或多个维度），方式是让其中一个或多个分量的组合概率为 1。

如果在二维随机变量  $(X, Y)$  的联合分布函数  $F(X, Y)$  中令  $y \rightarrow +\infty$ ，由于  $\{Y < +\infty\}$  为必然事件，故可得

$$\lim_{y \rightarrow +\infty} F(x, y) = P(X \leq x, Y < +\infty) = P(X \leq x),$$

这是一个一维分布函数，被称为  $X$  的边际分布，记为

$$F_X(x) = F(x, +\infty)$$

类似地，在  $F(x, y)$  中令  $x \rightarrow +\infty$ ，可得  $Y$  的边际分布

$$F_Y(y) = F(+\infty, y)$$

类似地，可以对一个五维联合分布进行维度压缩，可以得到 5 个一维边际分布、10 个二维边际分布、10 个三维边际分布和 5 个四维边际分布。但明显这种降维方式是直接将其中一个或多个分量通过概率加和消除掉，这种方式应用到实际里面对应离散变量就是加和，对于连续变量进行积分（进行投影），这种简单的降维方式其实连带着把和其他分量之间的关系也消除掉了。

### 3.2.2 边际分布函数形式

#### a. 离散变量的边际分布列

从边际分布函数的概念出发，可以采用边际分布列对离散变量的边际分布进行直观表示。在二维离散随机变量  $(X, Y)$  的联合分布列  $\{P(X = x_i, Y = y_j)\}$  中，对  $j$  求和所得的分布列

$$\sum_{j=1}^{+\infty} P(X = x_i, Y = y_j) = P(X = x_i), i = 1, 2, \dots$$

被称为  $X$  的边际分布列。类似地，对  $i$  求和所得的分布列

$$\sum_{i=1}^{+\infty} P(X = x_i, Y = y_j) = P(Y = y_j), j = 1, 2, \dots$$

被称为  $Y$  的边际分布列。在实际操作中，直接给出  $(X, Y)$  的联合分布列矩阵，然后进行逐行或逐列的加和即可。

#### b. 连续变量的边际密度函数

直接从边际分布函数的概念出发，再结合概率密度函数的概念，可以得到边际密度函数的概念，这种定义是完全对比得到的，是计算出来的定义、而非设定性的定义。如果二维连续随机变量  $(X, Y)$  的联合密度函数为  $p_{X,Y}(x, y)$ ，因为

$$F_X(x) = F_{X,Y}(x, +\infty) = \int_{-\infty}^x \left( \int_{-\infty}^{+\infty} p_{X,Y}(u, v) dv \right) du = \int_{-\infty}^x p_X(u) du,$$
$$F_Y(y) = F_{X,Y}(+\infty, y) = \int_{-\infty}^y \left( \int_{-\infty}^{+\infty} p_{X,Y}(u, v) du \right) dv = \int_{-\infty}^y p_Y(v) dv,$$

其中  $p_X(x)$  和  $p_Y(y)$  分别为

$$p_X(x) = \int_{-\infty}^{+\infty} p(x, y) dy.$$
$$p_Y(y) = \int_{-\infty}^{+\infty} p(x, y) dx.$$

对比后发现，二者分别正好都位于对应变量的密度函数的位置上，所以称这二者为边际密度函数。

#### c. 常见的边际分布

二维正态分布的边际分布是一维正态分布，以下求解过程必须牢记在心：

设  $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 。先把二维正态密度函数  $p(x, y)$  的指数部分

$$-\frac{1}{2(1 - \rho^2)} \left[ \frac{(x - \mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x - \mu_1)(y - \mu_2)}{\sigma_1 \sigma_2} + \frac{(y - \mu_2)^2}{\sigma_2^2} \right]$$

改写成（这一步的改写尤为重要，而且基本上所有的求解分都需要这一步改写！之所以这么改写是因为想要尽可能将  $x$  和  $y$  分离开）

$$-\frac{1}{2} \left[ \rho \frac{x - \mu_1}{\sigma_1 \sqrt{1 - \rho^2}} - \frac{y - \mu_2}{\sigma_2 \sqrt{1 - \rho^2}} \right]^2 - \frac{(x - \mu_1)^2}{2\sigma_1^2}.$$

再对积分

$$\int_{-\infty}^{+\infty} \exp \left\{ -\frac{1}{2} \left[ \rho \frac{x - \mu_1}{\sigma_1 \sqrt{1 - \rho^2}} - \frac{y - \mu_2}{\sigma_2 \sqrt{1 - \rho^2}} \right]^2 \right\} dy$$

作变换 (注意, 因为是对  $y$  进行积分, 所以可以把  $x$  看作常量)

$$t = \rho \frac{x - \mu_1}{\sigma_1 \sqrt{1 - \rho^2}} - \frac{y - \mu_2}{\sigma_2 \sqrt{1 - \rho^2}},$$

则

$$\begin{aligned} p_X(x) &= \int_{-\infty}^{+\infty} p(x, y) dy \\ &= \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ -\frac{(x - \mu_1)^2}{2\sigma_1^2} \right\} \sigma_2 \sqrt{1 - \rho^2} \int_{-\infty}^{+\infty} \exp \left\{ -\frac{t^2}{2} \right\} dt. \end{aligned}$$

注意到上式中的积分恰好等于  $\sqrt{2\pi}$  (通过正态分布求解) 所以有

$$p_X(x) = \frac{1}{\sqrt{2\pi}\sigma_1} \exp \left\{ -\frac{(x - \mu_1)^2}{2\sigma_1^2} \right\}.$$

这正是一维正态分布  $N(\mu_1, \sigma_1^2)$  的密度函数, 即  $X \sim N(\mu_1, \sigma_1^2)$ 。同理可证  $Y \sim N(\mu_2, \sigma_2^2)$ 。由此可见

- 二维正态分布的边际分布中不含参数  $\rho$  (在求解边际分布进行降维的时候失去了变量间的相关信息)
- 这说明二维正态分布  $N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, 0.1)$  与  $N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, 0.2)$  的边际分布是相同的。
- 具有相同边际分布的多维联合分布可以是不同的**, 也就是说由联合分布一定能求解出边际分布, 但由边际分布却不一定能反解联合分布 (下面我们就认识到, 只有当)。

### 3.2.3 随机变量间的独立性

随机事件的独立性我们之前已经探讨过了, 其是由随机事件发生的概率特性定义而来, 此处随机变量之间的独立性也是从这儿衍生出来的定义。先来从随机变量的角度上直观理解独立性的概念: 在多维随机变量中, 各分量的取值有时会相互影响, 但有时毫无影响。譬如一个人的身高  $X$  和体重  $Y$  就会相互影响, 但与收入  $Z$  一般无影响。当**两个随机变量取值的规律互不影响时**, 就称它们是相互独立的。

数学上的严格定义如下: 设  $n$  维随机变量  $(X_1, X_2, \dots, X_n)$  的联合分布函数为  $F(x_1, x_2, \dots, x_n)$ ,  $F_i(x_i)$  为  $X_i$  的边际分布函数, 如果对任意  $n$  个实数  $x_1, x_2, \dots, x_n$ , 有

$$F(x_1, x_2, \dots, x_n) = \prod_{i=1}^n F_i(x_i),$$

则称  $X_1, X_2, \dots, X_n$  相互独立。**随机变量相互独立的条件似乎比随机事件相互独立要弱?** 独立的定义一定是由概率出发的, 因此随机变量的定义式一定是从联合分布函数出发, 这一点毋庸置疑。但直接依靠定义判断独立性往往是不方便的, 通常借助如下推论:

- 在离散随机变量的场合下**直接借助分布列**: 如果对其任意  $n$  个取值  $x_1, x_2, \dots, x_n$ , 有

$$P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) = \prod_{i=1}^n P(X_i = x_i),$$

则称  $X_1, X_2, \dots, X_n$  相互独立。

- 在连续随机变量的场合下**直接借助概率密度函数**: 如果对任意  $n$  个实数  $x_1, x_2, \dots, x_n$ , 有

$$p_{X_1, X_2, \dots, X_n}(x_1, x_2, \dots, x_n) = \prod_{i=1}^n p_{X_i}(x_i),$$

则称  $X_1, X_2, \dots, X_n$  相互独立。

因此我们判断独立性的方法如下：

- **Step 1** 由联合概率密度函数/分布列求解出边际概率密度函数/分布列（积分 or 加和）
- **Step 2** 判断边际概率密度函数/分布列连乘结果是否等于联合概率密度函数/分布列

### 3.2.4 多维随机变量函数的分布

设  $(X_1, X_2, \dots, X_n)$  为  $n$  维随机变量，则  $Y = g(X_1, X_2, \dots, X_n)$  是  $(X_1, X_2, \dots, X_n)$  的函数， $Y$  是一维随机变量。现在的问题是如何由  $(X_1, X_2, \dots, X_n)$  的分布，求出  $Y$  的分布。可以看出  $g(\cdot)$  是一个多维随机变量向一维随机变量的映射关系，可以将其堪称是一个极致维度压缩与特征变换方式，现实中的线性回归或者深度学习就是做得这样的变换！我们所说服从二项分布的随机变量  $Y$  也可以看  $n$  维随机变量  $(X_1, X_2, \dots, X_n)$  其中  $X_i \sim 0 - 1(p)$  的函数  $Y = \sum_{i=1}^n X_i$ 。（一个很有意思的事：之前是从时间上前后进行  $n$  次实验的维度为二项分布下的定义，但由于每次实验的独立性，和时间并没有关系，因此我们就可以转变为空间上同时进行  $n$  次实验的维度。）

在求解此类问题的过程中，我们绝不使用任何的中间结论，直接从定义出发，在此以二维随机变量  $(X, Y)$  为例，定义  $Z = g(X, Y)$ ：

- **Step 0** 求解  $Z$  的范围，找到关键点，划分区间（左闭右开）
- **Step 1** 严格按照定义进行初始推导

$$\begin{aligned} F_Z(z) &= P\{Z \leq z\} \\ &= P\{g(X, Y) \leq z\} \end{aligned}$$

- **Step 2** 根据定义进行二元积分完成  $F_Z(z)$  的求解

$$F_Z(z) = \iint_{g(X, Y) \leq z} p_{X, Y}(x, y) dx dy$$

- **Step 3**  $F_Z(z)$  对  $z$  进行求导得到概率密度函数  $f_Z(z)$

$$f_Z(z) = \frac{dF_Z(z)}{dz}$$

**泊松分布的可加性：**设  $X \sim P(\lambda_1)$ ,  $Y \sim P(\lambda_2)$ ，且  $X$  与  $Y$  独立，则  $Z = X + Y \sim P(\lambda_1 + \lambda_2)$ 。

因为泊松分布是离散分布，所以直接给出分布列进行计算即可。关键是下面的式子：

$$P(Z = k) = \sum_{i=0}^k P(X = i)P(Y = k - i)$$

**正态分布的可加性：**设  $X \sim N(\mu_1, \sigma_1^2)$ ,  $Y \sim N(\mu_2, \sigma_2^2)$ ，且  $X$  与  $Y$  独立，则  $Z = X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$ 。

通过独立性简化计算

**Max()、Min() 的特性：**

- 设  $Y = \text{Max}(X_1, X_2, \dots, X_n)$ ，且  $X_1, X_2, \dots, X_n$  相互独立，则

$$\begin{aligned}
F_Y(y) &= P\{\text{Max}(X_1, X_2, \dots, X_n) \leq y\} \\
&= P\{X_1 \leq y, X_2 \leq y, \dots, X_n \leq y\} \\
&= \prod_{i=1}^n P\{X_i \leq y\} \\
&= \prod_{i=1}^n F_{X_i}(y)
\end{aligned}$$

- 设  $Y = \text{Min}(X_1, X_2, \dots, X_n)$ , 且  $X_1, X_2, \dots, X_n$  相互独立, 则

$$\begin{aligned}
F_Y(y) &= P\{\text{Min}(X_1, X_2, \dots, X_n) \leq y\} \\
&= 1 - P\{\text{Min}(X_1, X_2, \dots, X_n) > y\} \\
&= 1 - P\{X_1 > y, X_2 > y, \dots, X_n > y\} \\
&= 1 - \prod_{i=1}^n P\{X_i > y\} \\
&= 1 - \prod_{i=1}^n (1 - F_{X_i}(y))
\end{aligned}$$

### 3.3 多维随机变量的特征数

想要探究多维随机变量之间的关系, 就必须对变量之间的特征数进行细致地梳理。

拿到一个多维随机变量, 我们完全可以考虑以下的特征数:

- 各个分量的期望、方差、标准差以及相关运算后的关系。
- 两个随机变量间的关联程度, 即协方差与相关系数 (反映两个随机变量相依关系的特征数)

#### 3.3.1 多维随机变量函数的数字特征 (一维)

##### a. 数学期望

当进行了  $Z = g(X_1, X_2, \dots, X_n)$  这样的特征变换后, 我们当然希望再深入研究一下变量  $Z$  的性质, 比如说数学期望、方差等。针对  $Z$  这么一个一维变量 (这也是首先介绍这一特征数的原因, 因为多维随机变量函数本质是一个一维变量), 一个很显然的思路就是两步法

- Step 1** 求解  $Z$  的分布函数
- Step 2** 借助分布函数对相应的特征数进行求解

与此同时我们还能通过复杂的推导得到如下定理 (其本质是和一维随机变量数学期望的定理是一致的) : 若二维随机变量  $(X, Y)$  的分布用联合分布列  $P(X = x_i, Y = y_j)$  或用联合密度函数  $p(x, y)$  表示, 则  $Z = g(X, Y)$  的数学期望为

$$E(Z) = \begin{cases} \sum_i \sum_j g(x_i, y_j) P(X = x_i, Y = y_j), & \text{在离散场合,} \\ \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y) p(x, y) dx dy, & \text{在连续场合.} \end{cases}$$

这种方法通常来说较为简单: 不需要先求出  $Z$  的分布, 直接计算即可。但需要注意的是, 运算中存在的乘积可能导致函数求积分难以计算那此时必须要转换到定义法, 老老实实地按照两步走计算。**这个定理的核心功用是进行证明, 比如接下来我们将得到的相关性质。**

##### b. 一维随机变量组合的数学期望和方差运算性质

接下来我们重点看几个特殊的  $Z$ , 基于上述定理, 进而得到一些中间结论, 辅助我们对一维随机变量的组合结果有更深的认识。对于多个一维随机变量之间的运算, 我们总是下意识的就将其认为是多维随机变量, 这当然是错误的! 所以此处我们换一个更清晰的角度: 将其看作进行了一个  $g(X, Y)$  变换。这种思维在后续的统计中也是贯穿始终的!

1. (对任意的随机变量: 和的均值等于均值的和) 设  $(X, Y)$  是二维随机变量, 则有

$$E(X + Y) = E(X) + E(Y)$$

**【证明】** 从上述定理出发, 不妨设  $(X, Y)$  为连续随机变量, 其联合密度函数为  $p(x, y)$ , 若令  $g(X, Y) = X + Y$

$$\begin{aligned}
E(X+Y) &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} (x+y)p(x,y)dxdy \\
&= \int_{-\infty}^{+\infty} x \left\{ \int_{-\infty}^{+\infty} p(x,y)dy \right\} dx + \int_{-\infty}^{+\infty} y \left\{ \int_{-\infty}^{+\infty} p(x,y)dx \right\} dy \\
&= \int_{-\infty}^{+\infty} xp_X(x)dx + \int_{-\infty}^{+\infty} yp_Y(y)dy \\
&= E(X) + E(Y).
\end{aligned}$$

2. (对独立的随机变量: 积的均值等于均值的积) 若随机变量  $X$  与  $Y$  相互独立, 则有

$$E(XY) = E(X)E(Y)$$

【证明】同样是从上述定理出发, 只不过此时令  $g(X, Y) = XY$ , 自然发现必须要补上一个条件  $p(x, y) = p_X(x)p_Y(y)$ , 即两个随机变量相互独立, 才能得到如下推导:

$$\begin{aligned}
E(XY) &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} xyp_X(x)p_Y(y)dxdy \\
&= \int_{-\infty}^{+\infty} xp_X(x)dx \int_{-\infty}^{+\infty} yp_Y(y)dy \\
&= E(X)E(Y).
\end{aligned}$$

3. (对独立的随机变量: 和的方差等于方差的和) 若随机变量  $X$  与  $Y$  相互独立, 则有

$$Var(X \pm Y) = Var(X) \pm Var(Y)$$

【证明】由于方差是从均值来的, 所以在这就不直接从定理出发了, 而是借助已经得到的两条性质进行推导

$$\begin{aligned}
Var(X+Y) &= E((X+Y) - E(X+Y))^2 \\
&= E((X-E(X)) + (Y-E(Y)))^2 \\
&= Var(X) + Var(Y) + 2E(X-E(X))(Y-E(Y)).
\end{aligned}$$

当随机变量  $X$  与  $Y$  相互独立时, 最后一项为 0。

4. (对于独立的随机变量: 积的方差与方差的积没有确切关系) 不同于均值, 我们对方差进行推导时会发现

$$\begin{aligned}
Var(XY) &= E((XY)^2) - E(XY)^2 \\
&= E(X^2)E(Y^2) - E(X)^2E(Y)^2
\end{aligned}$$

但是:

$$Var(X)Var(Y) = E(X^2)E(Y^2) - E(X^2)E(Y)^2 - E(Y^2)E(X)^2 + E(X)^2E(Y)^2$$

显然二者相等是需要更多条件的!

### 3.3.2 多维随机变量之间的数字特征 (多维)

求解某一维的随机变量边际分布后, 就直接将该变量与其他变量之间的关系给抹去了, 那这个关系到底该如何表示呢?

### a. 协方差

设  $(X, Y)$  是一个二维随机变量，若  $E[(X - E(X))(Y - E(Y))]$  存在，则称此数学期望为  $X$  与  $Y$  的协方差，或称为  $X$  与  $Y$  的相关（中心）矩，并记为

$$Cov(X, Y) = E[(X - E(X))(Y - E(Y))] = E(XY) - E(X)E(Y)$$

从协方差的定义可以看出，它是  $X$  的线性偏差 “ $X - E(X)$ ” 与  $Y$  的线性偏差 “ $Y - E(Y)$ ” 乘积的数学期望。由于该线性偏差可正可负，故协方差也可正可负，也可为零，其具体表现如下：

- 当  $Cov(X, Y) > 0$  时，称  $X$  与  $Y$  正相关，这时两个线性偏差  $(X - E(X))$  与  $(Y - E(Y))$  同时增加或同时减少。由于  $E(X)$  与  $E(Y)$  都是常数，这也就等价于  $X$  与  $Y$  同时增加或同时减少，这就是正相关的含义。
- 当  $Cov(X, Y) < 0$  时，称  $X$  与  $Y$  负相关，这时  $X$  增加而  $Y$  减少，或  $Y$  增加而  $X$  减少，这就是负相关的含义。
- 当  $Cov(X, Y) = 0$  时，称  $X$  与  $Y$  不相关。

**一个老生常谈的结论：**相关性比独立性要弱得多， $X$  与  $Y$  不相关只能表明二者线性关系独立！这也就是说**独立一定不相关，反之只能证明线性关系独立。**

设随机变量  $X \sim N(0, \sigma^2)$ ，且令  $Y = X^2$ ，则  $X$  与  $Y$  显然不独立，而此时  $X$  与  $Y$  的协方差却为 0

$$Cov(X, Y) = Cov(X, X^2) = E(X \cdot X^2) - E(X)E(X^2) = 0.$$

这说明二者不相关。**但是能否找到一个线性变换  $Y = aX + b$  使得  $Cov(X, Y) = 0$  呢？** 对于正态分布貌似找不出来，我们可以很轻松地推算出如下结论：**在二维正态分布场合中，不相关与独立是等价的！！！**

依靠该定义，我们直接推出来如下几条性质（随便动手一算即可得到结果）：

- **用协方差表示方差：**

$$Var(X \pm Y) = Var(X) + Var(Y) + 2Cov(X, Y)$$

这个性质表明：如果  $X, Y$  是**负相关的**那么和的方差一定小于方差的和  $\Rightarrow$  分散风险的本质。

- **与常数之间的协方差为 0：**

$$Cov(X, c) = 0$$

- **线性变换的协方差：**

$$Cov(aX, bY) = abCov(X, Y)$$

- **多变量线性组合的协方差等于协方差的线性组合：**

$$Cov(X + Y, Z) = Cov(X, Z) + Cov(Y, Z)$$

**Schwarz 不等式：**对任意二维随机变量  $(X, Y)$ ，若  $X$  与  $Y$  的方差都存在，且记  $\sigma_X^2 = Var(X), \sigma_Y^2 = Var(Y)$ ，则有：

$$[Cov(X, Y)]^2 \leq \sigma_X^2 \sigma_Y^2.$$

**[证明]** 不妨设  $\sigma_X^2 > 0$ ，因为当  $\sigma_X^2 = 0$  时，结论显然成立。在  $\sigma_X^2 > 0$  成立下，考虑  $t$  的如下二次函数：

$$g(t) = E[t(X - E(X)) + (Y - E(Y))]^2 = t^2 \sigma_X^2 + 2t \cdot Cov(X, Y) + \sigma_Y^2.$$

由于上述的二次三项式非负，平方项系数  $\sigma_X^2$  为正，所以其判别式小于或等于零，即

$$[2\text{Cov}(X, Y)]^2 - 4\sigma_X^2\sigma_Y^2 \leq 0.$$

移项后即得施瓦茨不等式（太优雅了）！

### b. 相关系数

协方差表示是表示变量相关关系的一个绝对概念，就和方差表示随机变量离散程度一样，值是带量纲的，因而相互间不能进行比较。无法从协方差的绝对差异上看出变量相关性的差异，因此需要消除量纲的影响，对协方差除以相同量纲的量，就得到了相关系数的定义：设  $(X, Y)$  是一个二维随机变量，且  $\text{Var}(X) > 0, \text{Var}(Y) > 0$ ，则称

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)}\sqrt{\text{Var}(Y)}} = \frac{\text{Cov}(X, Y)}{\sigma_X\sigma_Y}$$

为  $X$  与  $Y$  的（线性）相关系数。当然，我们也可以换个角度来理解相关系数，无非就是消除量纲，那我完全可以先对随机变量消除量纲后再求一个“绝对”的协方差，因此相关系数的另一个解释是：它是相应标准化变量的协方差。若记  $X$  与  $Y$  的数学期望分别为  $\mu_X, \mu_Y$ ，其标准化变量为

$$X^* = \frac{X - \mu_X}{\sigma_X}, \quad Y^* = \frac{Y - \mu_Y}{\sigma_Y}$$

则有

$$\text{Cov}(X^*, Y^*) = \text{Cov}\left(\frac{X - \mu_X}{\sigma_X}, \frac{Y - \mu_Y}{\sigma_Y}\right) = \frac{\text{Cov}(X, Y)}{\sigma_X\sigma_Y} = \text{Corr}(X, Y)$$

**深入理解相关系数的本质是极其重要的：**因为相关系数是线性回归的核心，其所表示的线性关系是从协方差的定义处所衍生的。

由施瓦茨不等式可以得到相关系数的有界性

$$-1 \leq \text{Corr}(X, Y) \leq 1$$

进而我们可以推出线性相关的最大性质（二者相关系数为  $\pm 1$  并不表示绝对的在一条直线上，而是相对的依概率在一条直线上，这是根基！）  
 $\text{Corr}(X, Y) = \pm 1$  的充要条件是  $X$  与  $Y$  间几乎处处有线性关系，即存在  $a (\neq 0)$  与  $b$ ，使得

$$P(Y = aX + b) = 1.$$

其中当  $\text{Corr}(X, Y) = 1$  时，有  $a > 0$ ；当  $\text{Corr}(X, Y) = -1$  时，有  $a < 0$ 。

#### 【证明】

- 先证明充分性（十分显然）

若  $Y = aX + b$ ，则将  $\text{Var}(Y) = a^2\text{Var}(X), \text{Cov}(X, Y) = a \cdot \text{Cov}(X, X) = a \cdot \text{Var}(X)$  代入相关系数的定义中得

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X\sigma_Y} = \frac{a\text{Var}(X)}{|a|\text{Var}(X)} = \begin{cases} 1, & a > 0; \\ -1, & a < 0. \end{cases}$$

- 再证明必要性（十分优雅）

$$\text{Var}\left(\frac{X}{\sigma_X} \pm \frac{Y}{\sigma_Y}\right) = 2[1 \pm \text{Corr}(X, Y)]$$

所以当  $\text{Corr}(X, Y) = 1$  时，有

$$\text{Var}\left(\frac{X}{\sigma_X} - \frac{Y}{\sigma_Y}\right) = 0,$$

这个式子是关键，因为如果  $\text{Corr}(X, Y) = \pm 1$  的话，这方差就不为零了，通过切比雪夫不等式就可以继续往下推导。

由此得

$$\begin{aligned} P\left(\frac{X}{\sigma_X} - \frac{Y}{\sigma_Y} = c\right) &= 1 \\ P\left(Y = \frac{\sigma_Y}{\sigma_X}X - c\sigma_Y\right) &= 1. \end{aligned}$$

这就证明了：当  $\text{Corr}(X, Y) = 1$  时， $Y$  与  $X$  几乎处处线性正相关。负相关是同理的。**概率才是本质**

也正是基于这一性质，我们可以归纳出相关系数的本质含义：

- 相关系数  $\text{Corr}(X, Y)$  刻画了  $X$  与  $Y$  之间的线性关系强弱，因此也常称其为“线性相关系数”。
- 若  $\text{Corr}(X, Y) = 0$ ，则称  $X$  与  $Y$  不相关，不相关是指  $X$  与  $Y$  之间没有线性关系，但  $X$  与  $Y$  之间可能有其他的函数关系，譬如平方关系、对数关系等（**那如何才能像确定线性不相关一样确定其他函数不相关呢？**）。
- 若  $\text{Corr}(X, Y) = 1$ ，则称  $X$  与  $Y$  完全正相关；若  $\text{Corr}(X, Y) = -1$ ，则称  $X$  与  $Y$  完全负相关。所谓完全，就是指  $(X, Y)$  点集上，几乎每个点对应都是线性相关的（概率 = 1）
- 若  $0 < |\text{Corr}(X, Y)| < 1$ ，则称  $X$  与  $Y$  有“一定程度”的线性关系，相关程度都是有限的，有些点对应相关性不强（概率  $< 1$ ）
  - $|\text{Corr}(X, Y)|$  越接近于 1，则线性相关程度越高；
  - $|\text{Corr}(X, Y)|$  越接近于 0，则线性相关程度越低。

## 3.4 条件分布与条件期望

现实生活中，二维随机变量  $(X, Y)$  之间往往不是独立的（甚至说世界上根本不存在独立的两个随机变量<参考贝叶斯公式>），而是相互依存的，为了研究随机变量之间的依存关系，把条件概率引入设计相关的数学工具是一个很好的思路。

### 3.4.1 条件分布

条件分布的现实含义是什么？对二维随机变量  $(X, Y)$  而言，**所谓随机变量  $X$  的条件分布，就是在给定  $Y$  取某个值的条件下  $X$  的分布  $F_{X|Y}(x|y)$** 。比如，记  $X$  为人的体重， $Y$  为人的身高，则  $X$  与  $Y$  之间一定有相依关系，现在如果限定  $Y = 1.7(\text{m})$ ，在这个条件下体重  $X$  的分布  $F_{X|Y}(x|1.7)$  显然与  $X$  的无条件分布（无此限制下体重的分布） $F_X(x)$  会有很大的不同，一个显然的结论可能是条件分布下的均值较比无条件分布下的均值要大。之后所有和条件分布相关的讨论都是来自于随机事件的条件概率定义：

$$P(A|B) = \frac{P(AB)}{P(B)}$$

#### a. 离散随机变量的条件分布列

**定义：**设二维离散随机变量  $(X, Y)$  的联合分布列为

$$p_{ij} = P(X = x_i, Y = y_j), \quad i = 1, 2, \dots, \quad j = 1, 2, \dots.$$

仿照条件概率的定义，我们很容易地给出如下离散随机变量的**条件分布列**的定义。对一切使  $P(Y = y_j) = p_{\cdot j} = \sum_{i=1}^{+\infty} p_{ij} > 0$  的  $y_j$ ，

$$p_{i|j} = P(X = x_i | Y = y_j) = \frac{P(X = x_i, Y = y_j)}{P(Y = y_j)} = \frac{p_{ij}}{p_{\cdot j}}, \quad i = 1, 2, \dots$$

为给定  $Y = y_j$  条件下  $X$  的条件分布列，因此条件分布列的个数可以有很多个。

**例子：**两个例子，辅助理解条件分布列的概念

- 设随机变量  $X$  与  $Y$  相互独立, 且  $X \sim P(\lambda_1), Y \sim P(\lambda_2)$ 。在已知  $X + Y = n$  的条件下, 求  $X$  的条件分布。
 

直接套定义即可, 可以将  $Z = X + Y$  理解为与  $X$  相关的新变量
- 设在一段时间内进入某一商店的顾客人数  $X$  服从泊松分布  $P(\lambda)$ , 每个顾客购买某种物品的概率为  $p$ , 并且各个顾客是否购买该种物品相互独立, 求进入商店的顾客购买这种物品的人数  $Y$  的分布列。
 

这个地方明显条件概率比较好求,  $P(Y = k | X = m)$  就是一个二项分布。然后用全概率公式求解出来  $P_Y()$  即可。

这也就告诉我们, 如果直接求概率分布列不好求的话, 可以借助条件概率来完成, 这和事件的思想是一致的。

### b. 连续随机变量的条件密度函数

**定义:** 不同于事件或者离散变量, 连续变量的条件概率公式分母直接算是 0, 这显然是不能继续往下推导的, 因此对连续随机变量的条件分布和条件密度函数进行定义时, 需要用到无穷小极限逼近。这个过程在此不赘述, 直接给出定义结论

对一切使  $p_Y(y) > 0$  的  $y$ , 给定  $Y = y$  条件下  $X$  的条件分布函数和条件密度函数分别为

$$F_{X|Y}(x|y) = \int_{-\infty}^x \frac{p(u,y)}{p_Y(y)} du,$$

$$p_{X|Y}(x|y) = \frac{p(x,y)}{p_Y(y)}$$

需要注意条件分布函数和条件密度函数仍然是一个二元函数, 但是的核心变量是  $x$ , 可以将  $y$  看作一个常量。 $F_{X|Y}(x|y_1)$  和  $F_{X|Y}(x|y_2)$  是两个不同的关于变量  $X$  的函数, 也就是说  $F_{X|Y}(x|y)$  表示跟随  $y$  变化而变化的一簇分布函数, 和直觉相符。概率密度函数也是同理。

**性质:**

- 二维正态分布的边际分布和条件分布都是一维正态分布。其边际分布较为简单, 条件分布比较复杂。

### 3.4.2 条件数学期望

之前我们只探讨了条件分布 or 条件概率。举个例子, 基于现实世界中的观察, 我们认定人的身高和体重  $(X, Y)$  服从二维正态分布, 假设  $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ , 进而我可以得到条件概率密度函数, 推算出一维随机变量

$$(Y|X = x) \sim N\left(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x - \mu_1), \sigma_2^2(1 - \rho^2)\right)$$

也就是说, 在总体的分布的基础上上, 我们得到对于身高  $X = x$  的这一局部人群, 他们体重  $Y$  的条件分布。基于此, 就能顺势解答一个问题: **身高  $X = x$  的这一局部人群体重均值是多少呢?** 明显对该条件分布求解均值就可以了, 这就是条件分数学期望的含义, 计算上就是条件分布的数学期望。身高  $X = x$  的这一局部人群体重均值一定是关于  $x$  的函数而非  $y$  的函数, 因为在求均值的时候  $y$  已经被消掉了, 当条件  $X = x$  确定下来后, 结果也就确定了, 当其变化时结果也会变化。基于此我们可以给出条件数学期望的如下定义

**定义:** 条件分布的数学期望 (若存在) 称为条件期望

$$E(X|Y = y) = \begin{cases} \sum_i x_i P(X = x_i | Y = y), & (X, Y) \text{ 为二维离散随机变量}; \\ \int_{-\infty}^{+\infty} xp(x|y) dx, & (X, Y) \text{ 为二维连续随机变量}. \end{cases}$$

注意条件期望  $E(X|Y = y)$  是  $y$  的函数, 就和上面的例子所表现的那样, 对于  $y$  的不同取值, 条件期望  $E(X|Y = y)$  也在变化。例如,  $X$  表示中国成年人的身高, 则  $E(X)$  表示中国成年人的平均身高。若用  $Y$  表示中国成年人的足长, 则  $E(X|y = y)$  表示足长为  $y$  的中国成年人的平均身高, 我国公安部门研究获得:

$$E(X|Y = y) = 6.876y$$

这个公式对公安部门破案起着重要的作用，例如，测得案犯留下的足印长为 25.3cm，则由此公式可推算出此案犯身高约 174cm（如果辅之以假设检验，还可以推算出置信区间）。

**性质：**此处的条件期望性质可以类比全概率公式进行理解。通过上述分析，我们可以记

$$g(y) = E(X|Y = y)$$

进一步还可以将条件期望看成是随机变量  $Y$  的函数，记为  $E(X|Y) = g(Y)$ ，而将  $E(X|Y = y)$  看成是  $Y = y$  时  $E(X|Y)$  的一个取值，由此看出： $E(X|Y)$  本身也是一个随机变量，它所代表的含义是按照  $Y$  将总体划分为不同的局部，这些局部中  $X$  的均值与  $Y$  的关系，始终谨记其中的  $X$  已经被均值操作消除了，只留下  $Y$ 。基于此我们可以得到**重期望公式**

设  $(X, Y)$  是二维随机变量，且  $E(X)$  存在，则

$$E(X) = E(E(X|Y))$$

这个公式是极为有用的，两次均值代表了加权平均的加权平均。也就是想要求总体的某个特征的均值时，可以先将总体按照某一个特征划分成多个小的局部个体，先在所有的局部内部加权平均求出该特征的均值，然后再在总体分局部这一层面对已经求出的局部均值再平均。更准确的说法如下：要求在一个取值于很大范围上的指标  $x$  的均值  $E(X)$ ，这时会遇到计算上的各种困难。为此，我们换一种思维方式，去找一个与  $X$  有关的量  $Y$ ，用  $Y$  的不同取值把大范围划分成若干个小区域，先在小区域上求  $X$  的平均，再对此类平均求加权平均，即可得到大范围内  $X$  的平均  $E(X)$ 。

如要求全校学生的平均身高，可先求出每个班级学生的平均身高，然后再对各班级的平均身高作加权平均，其权重就是班级人数在全校学生中所占的比例。

其具体应用形式如下

- 如果  $Y$  是一个离散随机变量，则

$$E(X) = \sum_j E(X|Y = y_j)P(Y = y_j)$$

- 如果  $Y$  是一个连续随机变量，则

$$E(X) = \int_{-\infty}^{+\infty} E(X|Y = y)p_Y(y)dy$$

不难发现：该公式的形式和全概率公式简直如出一辙，可以理解为“全期望公式”，**核心思路都是分而治之然后加和**。通过几个典型的例子来深入理解一下：

- 口袋中有编号为  $1, 2, \dots, n$  的  $n$  个球，从中任取 1 球。若取到 1 号球，则得 1 分，且停止摸球。若取到  $i$  号球 ( $i \geq 2$ )，则得  $i$  分。且将此球放回，重新摸球。如此下去，试求得到的平均总分数。（分成  $n$  种情况，求条件期望后加总）
- 随机个数的随机变量和的数学期望：设  $X_1, X_2, \dots$  为一列独立同分布的随机变量，随机变量  $N$  只取正整数值，且  $N$  与  $\{X_n\}$  独立，请证明：

$$E\left(\sum_{i=1}^N X_i\right) = E(X_1)E(N).$$

**【证明】**

$$\begin{aligned}
E\left(\sum_{i=1}^N X_i\right) &= \sum_{n=1}^{+\infty}[E(\sum_{i=1}^n X_i|N=n) \cdot P(N=n)] \\
&= \sum_{n=1}^{+\infty}[nE(X_1) \cdot P(N=n)] \\
&= E(X_1) \sum_{n=1}^{+\infty}[n \cdot P(N=n)] \\
&= E(X_1)E(N)
\end{aligned}$$

也正是基于这个性质，我们才有了一些所谓的显而易见的结论（这些“显然”的结论如果细究起来真的要人命）

- 设一天内到达某商场的顾客数  $N$  是仅取非负整数值的随机变量，又设进入此商场的第  $i$  个顾客的购物金额为  $X_i$ ，可认为诸  $X_i$  是独立同分布的随机变量， $N$  与  $X_i$  相互独立，则一天营业额的期望值为  $\text{来的人数的期望} * \text{每一个人消费的期望}$
- 一只昆虫一次产卵数  $N$  服从参数为  $\lambda$  的泊松分布，每个卵能成活的概率是  $p$ ，可设  $X_i$  服从  $0-1$  分布，而  $\{X_i = 1\}$  表示第  $i$  个卵成活，则一只昆虫一次产卵后的平均成活卵数为  $\text{产卵个数的期望} * \text{每个卵存活的期望}$

## 3.5 考点与典例

### 3.5.1 考点 1

## 数理统计的基本概念（进入统计）

### 总体、样本以及样本统计量

#### 总体的定义和性质

**定义：**之前我们的讨论始终围绕着总体  $X$  的分布进行，但在实在的世界中我们很难看到总体。所以我们在聊统计时，无非聊两个问题：**理论推导得出**总体服从某一分布，可以得到样本相关数字特征；看到样本服从某一特性推测总体服从某一分布，或者样本是否显著。这就是总体和样本之间的关系。

#### 性质

1. 独立性：从总体中抽取的样本之间相互独立
2. 同分布：抽取的样本之间同分布
3. 表示方法：从总体  $X$  中抽取得到的样本记作  $X_1, X_2 \dots, X_n$  这些样本的实际观测值记为  $x_1, x_2, \dots, x_n$

#### 统计量

**定义：**能够用总体已知（绝不可能是未知）参数表征的样本数字特征，都是统计量，样本每次抽取都不一样，统计量也各有不同。

#### 常见统计量（重点！）

1. 样本的均值： $\bar{X} = \frac{1}{n} \sum_{i=1}^n (X_i)$
2. 样本的方差： $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$  这里是  $n-1$  而不是  $n$  的原因我们已经深刻了解到了自由度和含义。

3. 当然和总体数字特征一样，也会拥有标准差、原点矩（-0）、中心矩（-均值）但都不重要

最重要的特征！！！ 设总体  $X$  的均值为  $E(X)$  方差为  $D(X)$

1. 样本均值的期望:  $E(\bar{X}) = E(X)$
2. 样本均值的方差:  $D(\bar{X}) = \frac{1}{n}D(X)$
3. 样本方差的期望:  $E(S^2) = D(X)$  保证了无偏性
4. 样本方差的方差:  $D(S^2)$  可用卡方分布求解

## 各种由正态分布组合出来的新分布

### 卡方分布

定义：来自正态分布总体的  $n$  个随机变量 平方的和，就是一个服从 自由度为  $n$  的卡方分布。

性质

1. 自由度为  $n$  的卡方分布的均值为  $n$ ，方差为  $2n$ （数字特征，也很好证明，卡方分布本质是一种  $\Gamma$  分布）
2. 自由度分别为  $n_1, n_2$  的独立卡方分布加和服从自由度为  $n_1+n_2$  的卡方分布（用以求解分布中的未知参数，进而使得某分布服从卡方分布）

### t 分布（单变量检验）

定义：由两个独立的分布  $X, Y$  组合得到，其中  $X \sim N(0, 1)$ ,  $Y \sim$  自由度为  $n$  的卡方分布，则  $\frac{X}{\sqrt{Y/n}}$  服从自由度为  $n$  的 t 分布（谨记！）。

### F 分布（多变量检验）

定义：由两个相互独立的卡方分布，一个为  $X \sim$  自由度( $n_1$ )的卡方分布，一个为  $Y \sim$  自由度( $n_2$ )的卡方分布，组合得到  $F = \frac{X/n_1}{Y/n_2}$  服从  $F(n_1, n_2)$ 。

性质：和 t 分布互动一下，若  $T \sim t(n)$  则  $T^2 \sim F(1, n)$

### 分位点（查表）

只要记住四种分布的概率分布图，就明白分位点的含义了：

1. 正态分布、t 分布是关于  $y$  轴对称的；
2. 卡方和 F 分布所有值都大于 0。

## 正态分布总体下的样本分布（后续很多理论知识的基础）

先看单：假设总体  $X \sim N(\mu, \sigma^2)$ ,  $(X_1, X_2, \dots, X_n)$  为来自总体  $X$  的简单随机样本则：

1.  $\bar{X}$  服从  $N(\mu, \frac{\sigma^2}{n})$
2.  $\frac{(n-1)S^2}{\sigma^2}$  服从自由度为  $n-1$  的卡方分布。（这个定理的详细推导过程并不好做，但是直观能感受出来，借助该结论可以求解很多结论！）
3. 一个 t 分布（这是计量中做 t 检验的基础理论！）

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

服从自由度为  $n - 1$  的 t 分布，这个十分重要！

正是因为有了这些基础，就可以在总体和个体之间搭建分布进行详细计算了。

再看双：假设总体  $X \sim N(\mu_1, \sigma_1^2)$ ,  $Y \sim N(\mu_2, \sigma_2^2)$  从两总体中进行抽样，得到抽样结果，仍然可以构造相关统计量：

1. 
$$T = \frac{(\bar{X} - \mu_1) - (\bar{Y} - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \text{ 服从 } t(n_1 + n_2 - 2)$$

其中：

2. 
$$S_w = \sqrt{\frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}}$$

$$F = \frac{S_1^2 / \sigma_1^2}{S_2^2 / \sigma_2^2} \text{ 服从 } F(n_1 - 1, n_2 - 1)$$

## 参数估计 —— 由样本估计总体参数

知道总体大概呈什么分布情况，但是其中有些参数仍未知，所以需要根据所观察到得样本数据进行估计，或者类似于计量经济学对总体函数关系参数做估计。

注意：估计出来的参数，仍然是一个变量，仍然有均值方差

### 点估计

**定义：**最简单的估计方法，在样本上随便设定一个统计量（估计量），然后根据样本的估计值计算该统计量的值，令该值等于总体理论推导值，进而得出总体中未知变量

#### 矩估计（采用【矩】这一统计量进行估计）

##### 理论

1. 在总体上有：一阶原点矩  $E(X)$ , 二阶原点矩  $E(X^2)$ , 二阶中心矩  $D(X)$
2. 在样本上有：一阶原点矩  $\bar{X}$ , 二阶原点矩  $\frac{1}{n} \sum_{i=1}^n X_i^2$ , 二阶中心矩  $\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$

由中心极限定理可得，当  $n$  趋近于无穷大时，样本矩和总体矩相等，进而反解出目标变量。

##### 应用

1. 第一步先看有几个未知参数：如果有 1 个，优先使用低阶矩，如果有 2 个，一阶矩和二阶矩都要用上，二阶矩建议使用二阶中心矩；
2. 先在总体上构建矩估计方程，得到参数如何用总体特征表示；
3. 再在样本上估计出数字特征，反代回 2 得到估计值。

## 极大似然估计 (让看到的样本发生的概率最大化)

理论：对于带有未知参数的一个总体分布而言，观测到了一个确定的样本，让该样本发生概率最大的那个参数，才是好参数。

应用（尤其注意均匀分布 max 和 min 的情况）

1. Step 1：写出似然函数（离散连续两种情况）
2. Step 2：写出对数
3. Step 3：求解参数
4. Step 4：因为上面仅仅是观测值，不同的样本可能有不同的观测值，因此要把观测值 $x_i$ 换为样本值 $X_i$

最大似然估计的不变性 就是说如果 $\hat{\theta}$ 是参数 $\theta$ 的最大似然估计值，那么 $g(\hat{\theta})$ 也是 $g(\theta)$ 的最大似然估计值。也就是说：求解出来估计结果，可以进行函数转换。

## 点估计选择估计出来的结果的标准

目的：两种点估计方法，估计出来的最终结果可能有所不同，到底该怎么选呢？提供了许多的标准。

无偏性： $E(\hat{\theta}) = \theta$  则无偏，最明显的就是说，样本的二阶中心矩并不是无偏的，但样本方差是无偏的。其实无非就是对估计出的参数 $Y$ 进一步求期望，如果 $Y = \bar{X}$ 那就很简单了，但是如果 $Y = \max(X_1, X_2, \dots, X_n)$ 这就麻烦了，需要先把 $Y$ 的分布给出来<可以用公式！>然后再求均值 or 方差

有效性：只有无偏估计量才有资格比较有效性，两个无偏估计量谁的方差越小谁越有效，因此这个地方就和无偏性对应起来了，上面讲的是均值，此处讲的是方差。求方差的那一套拿过来直接用！

一致性：有效性暗含着一个趋势，是指随着样本容量越来越大，样本中所含的分布信息越来越多，估计出的参数越来越接近总体参数。

## 区间估计（一个硬币的两面）

定义：给定样本所得到的点估计虽然表面上只是一个确定的值，但实际上其再一个分布中（要不怎么会有均值方差呢，求无偏有效性呢？）我们当然可以根据这个分布来判断估计值可能所在的区间。

方法（在此我们只考虑正态分布总体） $N(\mu, \sigma^2)$ ，凡是不为该分布的，都通过中心极限定理，转变为该分布。

思路其实都是完全相同的：先找一个无偏估计量，然后将此无偏估计量和待估计参数结合起来构造一个常见的分布，然后反解即可。

1. 求 $\mu$ 的区间估计（总体的 $\mu$ 未知，但 $\sigma^2$ 已知）构建正态分布统计量

2. 求 $\mu$ 的区间估计（总体的 $\mu, \sigma^2$ 均未知）构建t统计量

这就是我们在做回归估计参数时，惯用的检验显著与否的手段。

3. 求 $\sigma^2$ 的区间估计（总体的 $\mu, \sigma^2$ 均未知）

4. 求 $\sigma^2$ 的区间估计（总体的 $\mu$ 已知，但 $\sigma^2$ 未知）

将上面卡方分布的分布改为 $\sum_{i=1}^n (x_i - \mu)^2$ 这样可以减少自由度的损失，更加精准。

当然，以上结论都是给的双侧，但是单侧的原理和上述完全相同，只要记住如何构造分布，就什么都不怕！

## 假设检验

这和上面一章参数估计是一脉相承的，上一章要求估计出某个参数的准确值。现在我们要根据样本情况，验证某个参数是否满足某些条件，在假设成立的前提下，小概率事件是否发生。

**定义**：从小概率事件是否发生的角度来讲这个故事：不论是参数估计还是假设检验，我们针对的始终是总体的参数。在不知道总体的某个参数时，可以假设该参数符合某种条件（比如均值为0），带着这个假设进入到实际样本中。问这么一个问题：在已有假设的基础上，实际样本产生的概率有多大，是不是一个小概率事件？如果在此假设下，样本发生的概率极小，反过来极小概率的事件发生了，那很有可能是假设错了，我们可以完全拒绝原假设。因此，关键在于判断该样本产生是否为小概率事件——基于已知统计量构建分布，同时怎么定义小概率事件？到底概率多小才算小，这就引出了置信水平或显著性水平。

两类错误：

1. 第一类错误：小概率事件不是没有可能发生，假设定义发生概率为5%的事件为小概率事件，那也意味着在原假设成立的情况下，仍有5%的可能性会发生样本所看到的小概率事件，因此如果直接把原假设拒绝了，那就有5%的可能性犯错。原假设明明为正确的，但却把他拒绝了的概率，就是显著性水平
2. 第二类错误：原假设明明错了，但是根据样本计算的统计量却接受了它的概率。这个算起来就不容易了，首先就需要正确的统计量到底是什么，然后带到犯错的区间内去求概率。

基本步骤：

1. 根据实际情况提出原假设  $H_0$  和备择假设  $H_1$ 。如果是双边的  $H_0$  肯定是等于， $H_1$  是不等于。但如果是单边的话刚开始设定  $H_0$  为与题中相反的方向（题中说减小，这个地方就设定为大于等于），备择假设和题中所说相符，然后将  $H_0$  转化为等于。
2. 假设  $H_0$  成立，构造适当的统计量
3. 基于该统计量，给定置信水平  $\alpha$  根据统计量的分布情况查表，确定拒绝域  $W$
4. 根据样本的观察值计算统计量的值，将其与拒绝域作比较并下结论。

统计量的构建 和上一章完全相同的四种情况，注意拒绝域的符号不要搞错。